Микроэконометрика

Вступительная лекция

Потанин Богдан Станиславович

старший преподаватель, кандидат экономических наук

2021-2022

Оценка складывается из трех элементов:

Оценка складывается из трех элементов:

- Домашнее задание №1 – 40%

Оценка складывается из трех элементов:

- Домашнее задание №1 – 40%
- Домашнее задание №2 – 40%

Оценка складывается из трех элементов:

- Домашнее задание №1 – 40%
- Домашнее задание №2 – 40%
- Экзамен – 20%

Оценка складывается из трех элементов:

- Домашнее задание №1 – 40%
- Домашнее задание №2 – 40%
- Экзамен – 20%

Экзамен проходит письменно в форме решения задач по материалам лекций.

Существуют два альтернативных способа получить оценку за экзамен:

О курсе
Организационная информация

Оценка складывается из трех элементов:

- Домашнее задание №1 – 40%
- Домашнее задание №2 – 40%
- Экзамен – 20%

Экзамен проходит письменно в форме решения задач по материалам лекций.

Существуют два альтернативных способа получить оценку за экзамен:

- Выступить с презентацией по интересной статье, в которой используются методы, изучаемые в курсе.

О курсе
Организационная информация

Оценка складывается из трех элементов:

- Домашнее задание №1 – 40%
- Домашнее задание №2 – 40%
- Экзамен – 20%

Экзамен проходит письменно в форме решения задач по материалам лекций.

Существуют два альтернативных способа получить оценку за экзамен:

- Выступить с презентацией по интересной статье, в которой используются методы, изучаемые в курсе.
- Принять участие в тестировании онлайн-версии курса.

Численное дифференцирование

Градиент, Якобиан и Гессиан

Имеется функция $f(x)$, где $x = (x_1, ..., x_n)^T$ это n-мерный вектор столбец и $f : R^n \rightarrow R$.

Численное дифференцирование

Градиент, Якобиан и Гессиан

Имеется функция $f(x)$, где $x = (x_1, ..., x_n)^T$ это n-мерный вектор столбец и $f : R^n \rightarrow R$.

- Градиент $\nabla f(x)$ – это вектор столбец частных производных функции по ее аргументам:

$$\nabla f(x) = \left(\frac{\partial f(x)}{\partial x_1}, ..., \frac{\partial f(x)}{\partial x_n}\right)^T, \qquad \nabla f(x)_i = \frac{\partial f(x)}{\partial x_i}$$

Численное дифференцирование

Градиент, Якобиан и Гессиан

Имеется функция $f(x)$, где $x=(x_1,...,x_n)^T$ это n-мерный вектор столбец и $f:R^n\rightarrow R$.

- Градиент $\nabla f(x)$ – это вектор столбец частных производных функции по ее аргументам:

$$\nabla f(x)=\left(\frac{\partial f(x)}{\partial x_1},...,\frac{\partial f(x)}{\partial x_n}\right)^T,\qquad \nabla f(x)_i=\frac{\partial f(x)}{\partial x_i}$$

- Гессиан $H(f(x))$ – это матрица вторых производных функции по ее аргументам:

$$H(f(x))_{ij}=\frac{\partial^2 f(x)}{\partial x_i\partial x_j}$$

Имеется функция $f(x)$, где $x = (x_1, ..., x_n)^T$ это n-мерный вектор столбец и $f : R^n \rightarrow R$.

- Градиент $\nabla f(x)$ – это вектор столбец частных производных функции по ее аргументам:

$$\nabla f(x) = \left(\frac{\partial f(x)}{\partial x_1}, ..., \frac{\partial f(x)}{\partial x_n}\right)^T, \qquad \nabla f(x)_i = \frac{\partial f(x)}{\partial x_i}$$

- Гессиан $H(f(x))$ – это матрица вторых производных функции по ее аргументам:

$$H(f(x))_{ij} = \frac{\partial^2 f(x)}{\partial x_i \partial x_j}$$

Рассмотрим функцию $g(x)$ такую, что $g : R^n \rightarrow R^m$. То есть на вход данная функция принимает n-мерный вектор, а возвращает m-мерный вектор. Через $g(x)_i$ обозначим i-й элемент возвращаемого $g(x)$ вектора.

Имеется функция $f(x)$, где $x = (x_1, ..., x_n)^T$ это n-мерный вектор столбец и $f : R^n \rightarrow R$.

- Градиент $\nabla f(x)$ – это вектор столбец частных производных функции по ее аргументам:

$$\nabla f(x) = \left(\frac{\partial f(x)}{\partial x_1}, ..., \frac{\partial f(x)}{\partial x_n}\right)^T, \qquad \nabla f(x)_i = \frac{\partial f(x)}{\partial x_i}$$

- Гессиан $H(f(x))$ – это матрица вторых производных функции по ее аргументам:

$$H(f(x))_{ij} = \frac{\partial^2 f(x)}{\partial x_i \partial x_j}$$

Рассмотрим функцию $g(x)$ такую, что $g : R^n \rightarrow R^m$. То есть на вход данная функция принимает n-мерный вектор, а возвращает m-мерный вектор. Через $g(x)_i$ обозначим i-й элемент возвращаемого $g(x)$ вектора.

- Якобиан $J(g(x))$ – это матрица, i-я строка которой является градиентом $g(x)_i$:

$$J(g(x))_{i,\text{все столбцы}} = \nabla g(x)_i$$

Для функции $f(x) = x_1^3 + x_1 * e^{x_2}$ получаем:

$$\nabla f(x) = \left(3x_1^2 + e^{x_2}, x_1 e^{x_2}\right)^T$$

Для функции $f(x) = x_1^3 + x_1 * e^{x_2}$ получаем:

$$\nabla f(x) = \left(3x_1^2 + e^{x_2}, x_1 e^{x_2}\right)^T$$
$$H\left(f(x)\right) = \begin{bmatrix} 6x_1 & e^{x_2} \\ e^{x_2} & x_1 e^{x_2} \end{bmatrix}$$

Численное дифференцирование

Примеры Градиента, Якобиана и Гессиана

Для функции $f(x) = x_1^3 + x_1 * e^{x_2}$ получаем:

$$\nabla f(x) = \left(3x_1^2 + e^{x_2}, x_1 e^{x_2}\right)^T$$

$$H(f(x)) = \begin{bmatrix} 6x_1 & e^{x_2} \\ e^{x_2} & x_1 e^{x_2} \end{bmatrix}$$

Для функции $g(x) = \begin{bmatrix} x_1^3 + x_1 * e^{x_2} \\ x_1 - x_2 \\ x_1 x_2^2 \end{bmatrix}$ имеем:

$$J(g(x)) = \begin{bmatrix} 3x_1^2 + e^{x_2} & x_1 e^{x_2} \\ 1 & -1 \\ x_2^2 & 2x_1 x_2 \end{bmatrix}$$

Иногда вывести аналитическую формулу для производной бывает достаточно сложно. В таких случаях удобно воспользоваться численным (приблизительным) дифференцированием. Рассмотрим алгоритм дифференцирования $f(x)$ по x_i.

Иногда вывести аналитическую формулу для производной бывает достаточно сложно. В таких случаях удобно воспользоваться численным (приблизительным) дифференцированием. Рассмотрим алгоритм дифференцирования $f(x)$ по x_i.

- Подбирается малое приращение ε и определяется аргумент с приращением $x_\varepsilon = (x_1, ..., x_i + \varepsilon, ..., x_n)$.

Иногда вывести аналитическую формулу для производной бывает достаточно сложно. В таких случаях удобно воспользоваться численным (приблизительным) дифференцированием. Рассмотрим алгоритм дифференцирования $f(x)$ по x_i.

- Подбирается малое приращение ε и определяется аргумент с приращением $x_\varepsilon = (x_1, ..., x_i + \varepsilon, ..., x_n)$.
- Осуществляется приблизительный расчет производной по некоторой формуле:

$$\textbf{Forward difference: } \frac{\partial f(x)}{\partial x_i} \approx \frac{f(x_\varepsilon) - f(x)}{\varepsilon}$$

Иногда вывести аналитическую формулу для производной бывает достаточно сложно. В таких случаях удобно воспользоваться численным (приблизительным) дифференцированием. Рассмотрим алгоритм дифференцирования $f(x)$ по x_i.

- Подбирается малое приращение ε и определяется аргумент с приращением $x_\varepsilon = (x_1, ..., x_i + \varepsilon, ..., x_n)$.
- Осуществляется приблизительный расчет производной по некоторой формуле:

$$\textbf{Forward difference: } \frac{\partial f(x)}{\partial x_i} \approx \frac{f(x_\varepsilon) - f(x)}{\varepsilon}$$

$$\textbf{Central difference: } \frac{\partial f(x)}{\partial x_i} \approx \frac{f(x_\varepsilon) - f(x_{-\varepsilon})}{2\varepsilon}$$

Иногда вывести аналитическую формулу для производной бывает достаточно сложно. В таких случаях удобно воспользоваться численным (приблизительным) дифференцированием. Рассмотрим алгоритм дифференцирования $f(x)$ по x_i.

- Подбирается малое приращение ε и определяется аргумент с приращением $x_\varepsilon = (x_1, ..., x_i + \varepsilon, ..., x_n)$.
- Осуществляется приблизительный расчет производной по некоторой формуле:

$$\textbf{Forward difference: } \frac{\partial f(x)}{\partial x_i} \approx \frac{f(x_\varepsilon) - f(x)}{\varepsilon}$$

$$\textbf{Central difference: } \frac{\partial f(x)}{\partial x_i} \approx \frac{f(x_\varepsilon) - f(x_{-\varepsilon})}{2\varepsilon}$$

Аналогичные формулы существуют и для вторых производных. Используя их можно приблизительно рассчитать Градиент, Гессиан и Якобиан функций.

Численная оптимизация позволяет находить приблизительный максимум или минимум функции без необходимости искать аналитическое решение.

Численная оптимизация позволяет находить приблизительный максимум или минимум функции без необходимости искать аналитическое решение.

- Методы **локальной** оптимизации (BFGS, градиентный спуск) как правило работают достаточно быстро, но позволяют находить лишь локальные экстремумы. Методы **глобальной** оптимизации (генетический алгоритм, метод отжига – SA) позволяют найти несколько экстремумов, один из которых может оказаться глобальным. Однако, глобальная оптимизация обычно крайне затратна по времени.

Численная оптимизация

Мотивация и классификация

Численная оптимизация позволяет находить приблизительный максимум или минимум функции без необходимости искать аналитическое решение.

- Методы **локальной** оптимизации (BFGS, градиентный спуск) как правило работают достаточно быстро, но позволяют находить лишь локальные экстремумы. Методы **глобальной** оптимизации (генетический алгоритм, метод отжига – SA) позволяют найти несколько экстремумов, один из которых может оказаться глобальным. Однако, глобальная оптимизация обычно крайне затратна по времени.
- Методы локальной оптимизации часто опираются на Градиент (градиентный спуск, ADAM) или Гессиан функции (BFGS, BHHH). В последнем случае число итераций алгоритма, как правило, оказывается меньше, но время каждой итерации – больше, особенно, при большом числе оцениваемых параметров.

Численная оптимизация позволяет находить приблизительный максимум или минимум функции без необходимости искать аналитическое решение.

- Методы **локальной** оптимизации (BFGS, градиентный спуск) как правило работают достаточно быстро, но позволяют находить лишь локальные экстремумы. Методы **глобальной** оптимизации (генетический алгоритм, метод отжига – SA) позволяют найти несколько экстремумов, один из которых может оказаться глобальным. Однако, глобальная оптимизация обычно крайне затратна по времени.
- Методы локальной оптимизации часто опираются на Градиент (градиентный спуск, ADAM) или Гессиан функции (BFGS, BHHH). В последнем случае число итераций алгоритма, как правило, оказывается меньше, но время каждой итерации – больше, особенно, при большом числе оцениваемых параметров.

Поскольку число оцениваемых параметров в эконометрических моделях, как правило, относительно невелико (в сравнении с моделями машинного обучения), то чаще используются алгоритмы, использующие информацию о Гессиане (BFGS, BHHH).

- Рассмотрим i.i.d. выборку $X=(X_1,...,X_n)$ из распределения с вектором параметров $\theta=(\theta_1,...,\theta_m)$. Оценка θ может быть получена при помощи метода максимального правдоподобия (ММП оценка) за счет максимизации функции правдоподобия по всем элементам вектора θ, то есть по каждому параметру:
$$\hat{\theta}=(\hat{\theta}_1,...,\hat{\theta}_m)=\underset{\theta_{\mathbf{1}},...,\theta_m}{\operatorname{argmax}}\, L(\theta_1,...,\theta_m;X)$$

- Рассмотрим i.i.d. выборку $X=(X_1,...,X_n)$ из распределения с вектором параметров $\theta=(\theta_1,...,\theta_m)$. Оценка θ может быть получена при помощи метода максимального правдоподобия (ММП оценка) за счет максимизации функции правдоподобия по всем элементам вектора θ, то есть по каждому параметру:
$$\hat{\theta}=(\hat{\theta}_1,...,\hat{\theta}_m)=\underset{\theta_1,...,\theta_m}{\operatorname{argmax}} L(\theta_1,...,\theta_m;X)$$
- ММП оценки состоятельные, асимптотически эффективные и асимптотически нормальные:
$$\sqrt{n}\left(\hat{\theta}-\theta\right)\xrightarrow{d}\mathcal{N}\left(\begin{bmatrix}0 & ... & 0\end{bmatrix}^T, i^{-1}(\theta)\right)$$
Где $i(\theta)=E\left(-H\left(\ln L(\theta;X_1)\right)\right)$ именуется информацией Фишера.

Метод максимального правдоподобия

Формулировка

- Рассмотрим i.i.d. выборку $X = (X_1, ..., X_n)$ из распределения с вектором параметров $\theta = (\theta_1, ..., \theta_m)$. Оценка θ может быть получена при помощи метода максимального правдоподобия (ММП оценка) за счет максимизации функции правдоподобия по всем элементам вектора θ, то есть по каждому параметру:

$$\hat{\theta} = (\hat{\theta}_1, ..., \hat{\theta}_m) = \underset{\theta_1,...,\theta_m}{\operatorname{argmax}} L(\theta_1, ..., \theta_m; X)$$

- ММП оценки состоятельные, асимптотически эффективные и асимптотически нормальные:

$$\sqrt{n}\left(\hat{\theta} - \theta\right) \xrightarrow{d} \mathcal{N}\left(\begin{bmatrix}0 & ... & 0\end{bmatrix}^T, i^{-1}(\theta)\right)$$

  Где $i(\theta) = E\left(-H\left(\ln L(\theta; X_1)\right)\right)$ именуется информацией Фишера.

- Благодаря асимптотической нормальности для того, чтобы строить асимптотические доверительные интервалы и тестировать гипотезы с помощью ММП оценок достаточно найти их асимптотическую ковариационную матрицу:

$$As.Cov\left(\hat{\theta}\right) = (ni(\theta))^{-1}$$

- Имеется i.i.d. выборка $X = (X_1, ..., X_n)$ из нормального распределения $\mathcal{N}\left(\mu, \sigma^2\right)$. Логарифм функции правдоподобия будет иметь вид:

$$\ln L\left(\mu, \sigma; X\right) = \sum_{i=1}^{n} \ln\left(\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(X_i-\mu)^2}{2\sigma^2}}\right) = -0.5n\ln(2\pi) - n\ln(\sigma) - \frac{\sum\limits_{i=1}^{n}(X_i-\mu)^2}{2\sigma^2}$$

Метод максимального правдоподобия

Пример с нормальным распределением

- Имеется i.i.d. выборка $X = (X_1, ..., X_n)$ из нормального распределения $\mathcal{N}\left(\mu, \sigma^2\right)$. Логарифм функции правдоподобия будет иметь вид:

$$\ln L\left(\mu, \sigma; X\right) = \sum_{i=1}^{n} \ln\left(\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(X_i-\mu)^2}{2\sigma^2}}\right) = -0.5n\ln(2\pi) - n\ln(\sigma) - \frac{\sum\limits_{i=1}^{n}(X_i-\mu)^2}{2\sigma^2}$$

- Максимизируя по μ и σ^2 получаем ММП оценки соответствующих параметров:

$$\hat{\mu} = \frac{1}{n}\sum_{i=1}^{n} X_i, \qquad \hat{\sigma}^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i-\hat{\mu})^2$$

Метод максимального правдоподобия

Пример с нормальным распределением

- Имеется i.i.d. выборка $X = (X_1, ..., X_n)$ из нормального распределения $\mathcal{N}\left(\mu, \sigma^2\right)$. Логарифм функции правдоподобия будет иметь вид:

$$\ln L\left(\mu, \sigma; X\right) = \sum_{i=1}^{n} \ln\left(\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(X_i-\mu)^2}{2\sigma^2}}\right) = -0.5n\ln(2\pi) - n\ln(\sigma) - \frac{\sum\limits_{i=1}^{n}(X_i-\mu)^2}{2\sigma^2}$$

- Максимизируя по μ и σ^2 получаем ММП оценки соответствующих параметров:

$$\hat{\mu} = \frac{1}{n}\sum_{i=1}^{n} X_i, \qquad \hat{\sigma}^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i-\hat{\mu})^2$$

- Найдем информацию Фишера и асимптотическую ковариационную матрицу:

$$i\left(\left[\hat{\mu}, \hat{\sigma}^2\right]^T\right) = \begin{bmatrix}\sigma^{-1} & 0\\ 0 & 0.5\sigma^{-4}\end{bmatrix} \implies As.Cov\left(\left[\hat{\mu}, \hat{\sigma}^2\right]^T\right) = \begin{bmatrix}\sigma & 0\\ 0 & 2\sigma^4\end{bmatrix}$$

Метод максимального правдоподобия

Пример с нормальным распределением

- Имеется i.i.d. выборка $X = (X_1, ..., X_n)$ из нормального распределения $\mathcal{N}\left(\mu, \sigma^2\right)$. Логарифм функции правдоподобия будет иметь вид:

$$\ln L\left(\mu, \sigma; X\right) = \sum_{i=1}^{n} \ln\left(\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(X_i-\mu)^2}{2\sigma^2}}\right) = -0.5n\ln(2\pi) - n\ln(\sigma) - \frac{\sum\limits_{i=1}^{n}(X_i-\mu)^2}{2\sigma^2}$$

- Максимизируя по μ и σ^2 получаем ММП оценки соответствующих параметров:

$$\hat{\mu} = \frac{1}{n}\sum_{i=1}^{n} X_i, \qquad \hat{\sigma}^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \hat{\mu})^2$$

- Найдем информацию Фишера и асимптотическую ковариационную матрицу:

$$i\left(\left[\hat{\mu}, \hat{\sigma}^2\right]^T\right) = \begin{bmatrix}\sigma^{-1} & 0\\ 0 & 0.5\sigma^{-4}\end{bmatrix} \implies As.Cov\left(\left[\hat{\mu}, \hat{\sigma}^2\right]^T\right) = \begin{bmatrix}\sigma & 0\\ 0 & 2\sigma^4\end{bmatrix}$$

- В данном случае оценку асимптотической ковариационной матрицы можно получить за счет обычной замены σ^2 на $\hat{\sigma}^2$. Однако, на практике асимптотическую ковариационную матрицу может быть вывести крайне сложно, что мотивриует поиск альтернативных подходов к оцениванию.

Существуют три основных подхода к расчету асимптотической ковариационной матрицы:

Существуют три основных подхода к расчету асимптотической ковариационной матрицы:

- Обратный Гессиан – стандартный вариант:

$$\widehat{As.Cov}(\hat{\theta}) = H_*, \quad H_* = H^{-1}\left(-\ln L(\hat{\theta}; X)\right)$$

Существуют три основных подхода к расчету асимптотической ковариационной матрицы:

- Обратный Гессиан – стандартный вариант:

$$\widehat{As.Cov}(\hat{\theta}) = H_*, \quad H_* = H^{-1}\left(-\ln L(\hat{\theta}; X)\right)$$

- Произведение Якобианов (BHHH) – применяется, когда сложно посчитать Гессиан:

$$\widehat{As.Cov}(\hat{\theta}) = \left(J_*^T J_*\right)^{-1}, \quad J_* = J\left(\left(\ln L(\hat{\theta}; X_1), ..., \ln L(\hat{\theta}; X_n)\right)^T\right)$$

Метод максимального правдоподобия

Оценивание асимптотической ковариационной матрицы

Существуют три основных подхода к расчету асимптотической ковариационной матрицы:

- Обратный Гессиан – стандартный вариант:

$$\widehat{As.Cov}(\hat{\theta}) = H_*, \quad H_* = H^{-1}\left(-\ln L(\hat{\theta}; X)\right)$$

- Произведение Якобианов (BHHH) – применяется, когда сложно посчитать Гессиан:

$$\widehat{As.Cov}(\hat{\theta}) = \left(J_*^T J_*\right)^{-1}, \quad J_* = J\left(\left(\ln L(\hat{\theta}; X_1), ..., \ln L(\hat{\theta}; X_n)\right)^T\right)$$

- Сэндвич – устойчив к нарушению допущения о распределении (QMLE):

$$\widehat{As.Cov}(\hat{\theta}) = H_*^{-1} J_*^T J_* H_*^{-1}$$

Существуют три основных подхода к расчету асимптотической ковариационной матрицы:

- Обратный Гессиан – стандартный вариант:

$$\widehat{As.Cov}(\hat{\theta}) = H_*, \quad H_* = H^{-1}\left(-\ln L(\hat{\theta}; X)\right)$$

- Произведение Якобианов (BHHH) – применяется, когда сложно посчитать Гессиан:

$$\widehat{As.Cov}(\hat{\theta}) = \left(J_*^T J_*\right)^{-1}, \quad J_* = J\left(\left(\ln L(\hat{\theta}; X_1), ..., \ln L(\hat{\theta}; X_n)\right)^T\right)$$

- Сэндвич – устойчив к нарушению допущения о распределении (QMLE):

$$\widehat{As.Cov}(\hat{\theta}) = H_*^{-1} J_*^T J_* H_*^{-1}$$

- Бутстрап – когда численные производные плохо считаются или оценка $\hat{\theta}$ получена некоторым необычным методом (не ММП) и ее асимптотическое распределение неизвестно. Достаточно сформировать b выборок без возвращения из исходной выборки и по каждой из этих выборок оценить вектора параметров $\hat{\theta}^{(i)}$, где $i \in \{1, ..., b\}$. Затем асимптотическая ковариационная матрица оценивается как обычная выборочная ковариация по соответствующей выборке $(\hat{\theta}^{(1)}, ..., \hat{\theta}^{(b)})$.

- Рассмотрим функцию $g(\theta)$ и ММП оценку $\hat{\theta}$. В силу дельта метода оценка $g(\hat{\theta})$ будет асимптотически нормальной, причем:

$$As.E(g(\hat{\theta})) = g(\theta), \qquad As.Cov(g(\hat{\theta})) = \nabla g(\theta)^T As.Cov(\hat{\theta}) \nabla g(\theta)$$

- Рассмотрим функцию $g(\theta)$ и ММП оценку $\hat{\theta}$. В силу дельта метода оценка $g(\hat{\theta})$ будет асимптотически нормальной, причем:

$$As.E(g(\hat{\theta})) = g(\theta), \qquad As.Cov(g(\hat{\theta})) = \nabla g(\theta)^T As.Cov(\hat{\theta})\nabla g(\theta)$$

- Оценка асимптотической ковариационной матрицы будет иметь вид:

$$\widehat{As.Cov}\left(g(\hat{\theta})\right) = \nabla g(\hat{\theta})^T \widehat{As.Cov}(\hat{\theta})\nabla g(\hat{\theta})$$

- Рассмотрим функцию $g(\theta)$ и ММП оценку $\hat{\theta}$. В силу дельта метода оценка $g(\hat{\theta})$ будет асимптотически нормальной, причем:

$$As.E(g(\hat{\theta})) = g(\theta), \qquad As.Cov(g(\hat{\theta})) = \nabla g(\theta)^T As.Cov(\hat{\theta})\nabla g(\theta)$$

- Оценка асимптотической ковариационной матрицы будет иметь вид:

$$\widehat{As.Cov}\left(g(\hat{\theta})\right) = \nabla g(\hat{\theta})^T \widehat{As.Cov}(\hat{\theta})\nabla g(\hat{\theta})$$

- Для тестирования гипотез и построения доверительных интервалов для $g(\theta)$ достаточно воспользоваться полученной оценкой асимптотической ковариационной матрицы.

- Для тестирования гипотезы о параметре $H_0 : \theta_i = \theta_i^0$ сперва необходимо вычислить тестовую статистику:

$$T(X) = \frac{\hat{\theta}_i - \theta_i^0}{\sqrt{\widehat{As.Var}\left(\hat{\theta}_i\right)}}, \qquad \widehat{As.Var}\left(\hat{\theta}_i\right) = \widehat{As.Cov}(\hat{\theta})_{i,i}$$

- Для тестирования гипотезы о параметре $H_0 : \theta_i = \theta_i^0$ сперва необходимо вычислить тестовую статистику:

$$T(X) = \frac{\hat{\theta}_i - \theta_i^0}{\sqrt{\widehat{As.Var}\left(\hat{\theta}_i\right)}}, \qquad \widehat{As.Var}\left(\hat{\theta}_i\right) = \widehat{As.Cov}(\hat{\theta})_{i,i}$$

- Далее в силу асимптотической нормальности ММП оценок и теоремы Слуцкого получаем, что:

$$T(X)|H_0 \xrightarrow{d} \mathcal{N}(0,1)$$

- Для тестирования гипотезы о параметре $H_0 : \theta_i = \theta_i^0$ сперва необходимо вычислить тестовую статистику:

$$T(X) = \frac{\hat{\theta}_i - \theta_i^0}{\sqrt{\widehat{As.Var}\left(\hat{\theta}_i\right)}}, \qquad \widehat{As.Var}\left(\hat{\theta}_i\right) = \widehat{As.Cov}(\hat{\theta})_{i,i}$$

- Далее в силу асимптотической нормальности ММП оценок и теоремы Слуцкого получаем, что:

$$T(X)|H_0 \xrightarrow{d} \mathcal{N}(0,1)$$

- Поэтому p-value считается с помощью функции распределения стандартного нормального распределения:

$$\text{p-value} = 2\min\left(\Phi\left(T(X)\right), 1 - \Phi\left(T(X)\right)\right)$$

- Для тестирования гипотезы о функции от параметров $H_0 : g(\theta) = g^0$ сперва необходимо вычислить тестовую статистику:

$$T(X) = \frac{g(\hat{\theta}) - g^0}{\sqrt{\widehat{As.Var}\left(g(\hat{\theta})\right)}}, \qquad \widehat{As.Var}\left(g(\hat{\theta})\right) = \widehat{As.Cov}(g(\hat{\theta}))_{i,i}$$

- Для тестирования гипотезы о функции от параметров $H_0 : g(\theta) = g^0$ сперва необходимо вычислить тестовую статистику:

$$T(X) = \frac{g(\hat{\theta}) - g^0}{\sqrt{\widehat{As.Var}\left(g(\hat{\theta})\right)}}, \qquad \widehat{As.Var}\left(g(\hat{\theta})\right) = \widehat{As.Cov}(g(\hat{\theta}))_{i,i}$$

- Далее в силу дельта метода и теоремы Слуцкого получаем, что:

$$T(X)|H_0 \xrightarrow{d} \mathcal{N}(0,1)$$

- Для тестирования гипотезы о функции от параметров $H_0 : g(\theta) = g^0$ сперва необходимо вычислить тестовую статистику:

$$T(X) = \frac{g(\hat{\theta}) - g^0}{\sqrt{\widehat{As.Var}\left(g(\hat{\theta})\right)}}, \qquad \widehat{As.Var}\left(g(\hat{\theta})\right) = \widehat{As.Cov}(g(\hat{\theta}))_{i,i}$$

- Далее в силу дельта метода и теоремы Слуцкого получаем, что:

$$T(X)|H_0 \xrightarrow{d} \mathcal{N}(0,1)$$

- Поэтому p-value считается с помощью функции распределения стандартного нормального распределения:

$$\text{p-value} = 2\min\left(\Phi\left(T(X)\right), 1 - \Phi\left(T(X)\right)\right)$$

- Тестируется гипотеза об r ограничениях на параметры:

$$H_0 : \begin{cases} g_1(\theta) = 0 \\ \dots \\ g_r(\theta) = 0 \end{cases}, \qquad g(\theta) = \begin{bmatrix} g_1(\theta) \\ \dots \\ g_r(\theta) \end{bmatrix}$$

- Тестируется гипотеза об r ограничениях на параметры:

$$H_0 : \begin{cases} g_1(\theta) = 0 \\ \dots \\ g_r(\theta) = 0 \end{cases}, \qquad g(\theta) = \begin{bmatrix} g_1(\theta) \\ \dots \\ g_r(\theta) \end{bmatrix}$$

- Для проведения теста отношения правдоподобий (LR-тест) необходимо сперва найти ММП оценки $\hat{\theta}$ без учета ограничений, то есть обычным образом.

- Тестируется гипотеза об r ограничениях на параметры:

$$H_0 : \begin{cases} g_1(\theta) = 0 \\ ... \\ g_r(\theta) = 0 \end{cases}, \qquad g(\theta) = \begin{bmatrix} g_1(\theta) \\ ... \\ g_r(\theta) \end{bmatrix}$$

- Для проведения теста отношения правдоподобий (LR-тест) необходимо сперва найти ММП оценки $\hat{\theta}$ без учета ограничений, то есть обычным образом.
- Затем находятся оценки с учетом ограничений, то есть за счет максимизации функции правдоподобия с учетом ограничений на параметры, накладываемых нулевой гипотезой $\hat{\theta}^R$.

- Тестируется гипотеза об r ограничениях на параметры:

$$H_0 : \begin{cases} g_1(\theta) = 0 \\ \dots \\ g_r(\theta) = 0 \end{cases}, \qquad g(\theta) = \begin{bmatrix} g_1(\theta) \\ \dots \\ g_r(\theta) \end{bmatrix}$$

- Для проведения теста отношения правдоподобий (LR-тест) необходимо сперва найти ММП оценки $\hat{\theta}$ без учета ограничений, то есть обычным образом.
- Затем находятся оценки с учетом ограничений, то есть за счет максимизации функции правдоподобия с учетом ограничений на параметры, накладываемых нулевой гипотезой $\hat{\theta}^R$.
- Далее, рассчитываются тестовая статистика и p-value:

$$T(X) = 2\left(\ln L(\hat{\theta}) - \ln L(\hat{\theta}^R)\right), \quad T(X)|H_0 \xrightarrow{d} \chi^2(r) \implies \text{p-value} = 1 - F_{\chi^2(r)}(T(X))$$

- Тестируемая гипотеза, асимптотическое распределение тестовой статистики при верной нулевой гипотезе и способ расчета p-value аналогичны LR-тесту.

- Тестируемая гипотеза, асимптотическое распределение тестовой статистики при верной нулевой гипотезе и способ расчета p-value аналогичны LR-тесту.
- Преимущество теста Вальда над LR-тестом заключается в том, что для расчета тестовой статистики достаточно оценить лишь модель без ограничений:

$$T(X) = g(\hat{\theta})^T \left(\nabla g(\hat{\theta})^T \widehat{As.Cov}\left(\hat{\theta}\right) \nabla g(\hat{\theta})\right)^{-1} g(\hat{\theta})$$

- Тестируемая гипотеза, асимптотическое распределение тестовой статистики при верной нулевой гипотезе и способ расчета p-value аналогичны LR-тесту.
- Преимущество теста Вальда над LR-тестом заключается в том, что для расчета тестовой статистики достаточно оценить лишь модель без ограничений:

$$T(X) = g(\hat{\theta})^T \left(\nabla g(\hat{\theta})^T \widehat{As.Cov}\left(\hat{\theta}\right) \nabla g(\hat{\theta})\right)^{-1} g(\hat{\theta})$$

- Данный тест удобно применять в случаях, когда на модель накладываются сложные ограничений, максимизация правдоподобия при условии которых является затруднительной технической задачей.

- Тестируемая гипотеза, асимптотическое распределение тестовой статистики при верной нулевой гипотезе и способ расчета p-value аналогичны LR-тесту.

- Тестируемая гипотеза, асимптотическое распределение тестовой статистики при верной нулевой гипотезе и способ расчета p-value аналогичны LR-тесту.
- Преимущество теста множителей Лагранжа (LM-тест) над LR-тестом и тестом Вальда заключается в том, что для расчета тестовой статистики достаточно оценить лишь модель с ограничениями:

$$T(X) = \nabla \ln L_F(\hat{\theta}^R; X)^T \left(\widehat{As.Cov}_F\left(\hat{\theta}^R\right)\right)^{-1} \nabla \ln L_F(\hat{\theta}^R; X)$$

- Тестируемая гипотеза, асимптотическое распределение тестовой статистики при верной нулевой гипотезе и способ расчета p-value аналогичны LR-тесту.
- Преимущество теста множителей Лагранжа (LM-тест) над LR-тестом и тестом Вальда заключается в том, что для расчета тестовой статистики достаточно оценить лишь модель с ограничениями:

$$T(X) = \nabla \ln L_F(\hat{\theta}^R; X)^T \left(\widehat{As.Cov}_F\left(\hat{\theta}^R\right)\right)^{-1} \nabla \ln L_F(\hat{\theta}^R; X)$$

Где под L_F и $\widehat{As.Cov}_F$ подразумевается, что мы рассчитываем логарифм правдоподобия и считаем выражение для оценки асимптотической ковариационной матрицы в точках, соответствующих оценкам ограниченной модели $\hat{\theta}^R$, но с использованием правдоподобия полной модели.

- Тестируемая гипотеза, асимптотическое распределение тестовой статистики при верной нулевой гипотезе и способ расчета p-value аналогичны LR-тесту.
- Преимущество теста множителей Лагранжа (LM-тест) над LR-тестом и тестом Вальда заключается в том, что для расчета тестовой статистики достаточно оценить лишь модель с ограничениями:

$$T(X) = \nabla \ln L_F(\hat{\theta}^R; X)^T \left(\widehat{As.Cov}_F\left(\hat{\theta}^R\right)\right)^{-1} \nabla \ln L_F(\hat{\theta}^R; X)$$

Где под L_F и $\widehat{As.Cov}_F$ подразумевается, что мы рассчитываем логарифм правдоподобия и считаем выражение для оценки асимптотической ковариационной матрицы в точках, соответствующих оценкам ограниченной модели $\hat{\theta}^R$, но с использованием правдоподобия полной модели.

- Данный тест удобно применять в случаях, когда ограниченная модель оценивается проще, чем полная.