

Микроэконометрика

Вступительная лекция

Потанин Богдан Станиславович

доцент, кандидат экономических наук

2024-2025

Оценка складывается из четырех элементов:

- Домашнее задание №1 – 30%
- Домашнее задание №2 – 30%
- Презентация – 20%
- Экзамен – 20%

Презентацию можно делать либо индивидуально, либо в паре с другим студентом.

Численное дифференцирование

Градиент, Якобиан и Гессиан

Имеется функция $f(x)$, где $x = (x_1, \dots, x_n)^T$ это n -мерный вектор столбец и $f : R^n \rightarrow R$.

- Градиент $\nabla f(x)$ – это вектор столбец частных производных функции по ее аргументам:

$$\nabla f(x) = \left(\frac{\partial f(x)}{\partial x_1}, \dots, \frac{\partial f(x)}{\partial x_n} \right)^T, \quad \nabla f(x)_i = \frac{\partial f(x)}{\partial x_i}$$

- Гессиан $H(f(x))$ – это матрица вторых производных функции по ее аргументам:

$$H(f(x))_{ij} = \frac{\partial^2 f(x)}{\partial x_i \partial x_j}$$

Рассмотрим функцию $g(x)$ такую, что $g : R^n \rightarrow R^m$. То есть на вход данная функция принимает n -мерный вектор, а возвращает m -мерный вектор. Через $g(x)_i$ обозначим i -й элемент возвращаемого $g(x)$ вектора.

- Якобиан $J(g(x))$ – это матрица, i -я строка которой является градиентом $g(x)_i$:

$$J(g(x))_{i, \text{все столбцы}} = \nabla g(x)_i$$

Численное дифференцирование

Примеры Градиента, Якобиана и Гессиана

Для функции $f(x) = x_1^3 + x_1 e^{x_2}$ получаем:

$$\nabla f(x) = (3x_1^2 + e^{x_2}, x_1 e^{x_2})^T$$

$$H(f(x)) = \begin{bmatrix} 6x_1 & e^{x_2} \\ e^{x_2} & x_1 e^{x_2} \end{bmatrix}$$

Для функции $g(x) = \begin{bmatrix} x_1^3 + x_1 e^{x_2} \\ x_1 - x_2 \\ x_1 x_2^2 \end{bmatrix}$ имеем:

$$J(g(x)) = \begin{bmatrix} 3x_1^2 + e^{x_2} & x_1 e^{x_2} \\ 1 & -1 \\ x_2^2 & 2x_1 x_2 \end{bmatrix}$$

Численное дифференцирование

Формулы численного дифференцирования

Иногда вывести аналитическую формулу для производной бывает достаточно сложно. В таких случаях удобно воспользоваться численным (приблизительным) дифференцированием. Рассмотрим алгоритм дифференцирования $f(x)$ по x_i .

- Подбирается малое приращение $\varepsilon > 0$ и определяется аргумент с приращением $x_\varepsilon = (x_1, \dots, x_i + \varepsilon, \dots, x_n)$.
- Осуществляется приблизительный расчет производной по некоторой формуле:

$$\text{Forward difference: } \frac{\partial f(x)}{\partial x_i} \approx \frac{f(x_\varepsilon) - f(x)}{\varepsilon}$$

$$\text{Central difference: } \frac{\partial f(x)}{\partial x_i} \approx \frac{f(x_\varepsilon) - f(x_{-\varepsilon})}{2\varepsilon}$$

Аналогичные формулы существуют и для вторых производных. Используя их можно приблизительно рассчитать Градиент, Гессиан и Якобиан функций.

Численное дифференцирование

Пример

Продифференцируем функцию $f(x) = x_1^2 x_2$ в точке $x_1 = 3$, $x_2 = 5$ двумя способами.

- Аналитическое дифференцирование:

$$\frac{\partial f(x)}{\partial x_1} = 2x_1 x_2 \implies \frac{\partial f(3, 5)}{\partial x_1} = 2 \times 3 \times 5 = 30$$

$$\frac{\partial f(x)}{\partial x_2} = x_1^2 \implies \frac{\partial f(3, 5)}{\partial x_2} = 3^2 = 9$$

- Численное дифференцирование методом forward difference с приращением $\varepsilon = 0.001$:

$$\frac{\partial f(3, 5)}{\partial x_1} \approx \frac{f(3 + 0.001, 5) - f(3, 5)}{0.001} = \frac{(3 + 0.001)^2 \times 5 - 3^2 \times 5}{0.001} = 30.005$$

$$\frac{\partial f(3, 5)}{\partial x_2} \approx \frac{f(3, 5 + 0.001) - f(3, 5)}{0.001} = \frac{3^2 \times (5 + 0.001) - 3^2 \times 5}{0.001} = 9$$

Численная оптимизация

Мотивация и классификация

Численная оптимизация позволяет находить приблизительный максимум или минимум функции без необходимости искать аналитическое решение.

- Методы **локальной** оптимизации (BFGS, градиентный спуск) как правило работают достаточно быстро, но позволяют находить лишь локальные экстремумы. Методы **глобальной** оптимизации (генетический алгоритм, метод отжига – SA) позволяют найти несколько экстремумов, один из которых может оказаться глобальным. Однако, глобальная оптимизация обычно крайне затратна по времени.
- Методы локальной оптимизации часто опираются на Градиент (градиентный спуск, ADAM) или Гессиан функции (BFGS, BHHH). В последнем случае число итераций алгоритма, как правило, оказывается меньше, но время каждой итерации – больше, особенно, при большом числе оцениваемых параметров.

Поскольку число оцениваемых параметров в эконометрических моделях, как правило, относительно невелико (в сравнении с моделями машинного обучения), то чаще используются алгоритмы, использующие информацию о Гессиане (BFGS, BHHH).

Численная оптимизация

Пример с использованием градиентного спуска

Алгоритм **градиентного спуска** является одним из простейших численных методов нахождения минимума функции.

- Выбираем произвольную начальную точку x_0 .
- Считаем градиент функции в этой точке $\nabla f(x_0)$.
- Переходим в новую точку $x_1 = x_0 - \alpha \nabla f(x_0)$, где α – малая положительная константа.
- Повторяем процедуру до тех пор, пока не будут соблюдены условия остановки, например, о том, что $|\nabla f(x_0)| < \varepsilon$, где ε – маленькое положительное число.

Нетрудно показать аналитически, что функция $f(x) = x^2 - 2x$ достигает минимума в точке $x^* = 1$. В качестве альтернативы аналитическому решению попробуем приблизиться к минимуму с помощью 10 итераций описанного алгоритма, произвольным образом полагая $x_0 = 3$ и $\alpha = 0.2$.

| i | 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 |
|-----------------|---|------|-------|-------|-------|-------|-------|-------|-------|-------|-------------|
| x_i | 3 | 2.20 | 1.72 | 1.43 | 1.26 | 1.16 | 1.09 | 1.06 | 1.03 | 1.02 | 1.01 |
| $\nabla f(x_i)$ | 4 | 2.40 | 1.44 | 0.86 | 0.52 | 0.31 | 0.19 | 0.11 | 0.07 | 0.04 | 0.02 |
| $f(x_i)$ | 3 | 0.44 | -0.48 | -0.81 | -0.93 | -0.98 | -0.99 | -1.00 | -1.00 | -1.00 | -1.00 |

Метод максимального правдоподобия

Формулировка

- Рассмотрим i.i.d. выборку $X = (X_1, \dots, X_n)$ из распределения с вектором параметров $\theta = (\theta_1, \dots, \theta_m)$. Оценка θ может быть получена при помощи метода максимального правдоподобия (ММП оценка) за счет максимизации функции правдоподобия по всем элементам вектора θ , то есть по каждому параметру:

$$\hat{\theta} = (\hat{\theta}_1, \dots, \hat{\theta}_m) = \underset{\theta_1, \dots, \theta_m}{\operatorname{argmax}} L(\theta_1, \dots, \theta_m; X)$$

- ММП оценки состоятельные, асимптотически эффективные и асимптотически нормальные:

$$\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} \mathcal{N}\left([0 \quad \dots \quad 0]^T, i^{-1}(\theta)\right)$$

Где $i(\theta) = E(-H(\ln L(\theta; X_1)))$ именуется информацией Фишера.

- Благодаря асимптотической нормальности для того, чтобы строить асимптотические доверительные интервалы и тестировать гипотезы с помощью ММП оценок достаточно найти их асимптотическую ковариационную матрицу:

$$\text{As.Cov}(\hat{\theta}) = (ni(\theta))^{-1} = \frac{i(\theta)^{-1}}{n}$$

Метод максимального правдоподобия

Пример с нормальным распределением

- Имеется i.i.d. выборка $X = (X_1, \dots, X_n)$ из нормального распределения $\mathcal{N}(\mu, \sigma^2)$. Логарифм функции правдоподобия будет иметь вид:

$$\ln L(\mu, \sigma^2; X) = \sum_{i=1}^n \ln \left(\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(X_i - \mu)^2}{2\sigma^2}} \right) = -0.5n \ln(2\pi) - n \ln(\sigma) - \frac{\sum_{i=1}^n (X_i - \mu)^2}{2\sigma^2}$$

- Максимизируя по μ и σ^2 получаем ММП оценки соответствующих параметров:

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \hat{\mu})^2$$

- Найдем информацию Фишера и асимптотическую ковариационную матрицу:

$$i([\hat{\mu}, \hat{\sigma}^2]^T) = \begin{bmatrix} \sigma^{-2} & 0 \\ 0 & 0.5\sigma^{-4} \end{bmatrix} \Rightarrow \text{As.Cov}([\hat{\mu}, \hat{\sigma}^2]^T) = \begin{bmatrix} \sigma^2/n & 0 \\ 0 & 2\sigma^4/n \end{bmatrix}$$

- В данном случае оценку асимптотической ковариационной матрицы можно получить за счет обычной замены σ^2 на $\hat{\sigma}^2$. Однако, на практике асимптотическую ковариационную матрицу может быть вывести крайне сложно, что мотивирует поиск альтернативных подходов к оцениванию.

Метод максимального правдоподобия

Оценивание асимптотической ковариационной матрицы

Существуют три основных подхода к расчету асимптотической ковариационной матрицы:

- Обратный Гессиан – стандартный вариант:

$$\widehat{As.Cov}(\hat{\theta}) = H_*, \quad H_* = H^{-1} \left(-\ln L(\hat{\theta}; X) \right)$$

- Произведение Якобианов (ВННН) – применяется, когда сложно посчитать Гессиан:

$$\widehat{As.Cov}(\hat{\theta}) = \left(J_*^T J_* \right)^{-1}, \quad J_* = J \left(\left(\ln L(\hat{\theta}; X_1), \dots, \ln L(\hat{\theta}; X_n) \right)^T \right)$$

- Сэндвич – устойчив к нарушению допущения о распределении (QMLE):

$$\widehat{As.Cov}(\hat{\theta}) = H_*^{-1} J_*^T J_* H_*^{-1}$$

- Бутстрап – когда численные производные плохо считаются или оценка $\hat{\theta}$ получена некоторым необычным методом (не ММП) и ее асимптотическое распределение неизвестно. Достаточно сформировать b выборок с возвращением из исходной выборки и по каждой из этих выборок оценить вектора параметров $\hat{\theta}^{(i)}$, где $i \in \{1, \dots, b\}$. Затем асимптотическая ковариационная матрица оценивается как обычная выборочная ковариация по соответствующей выборке $(\hat{\theta}^{(1)}, \dots, \hat{\theta}^{(b)})$.

Метод максимального правдоподобия

Пример оценивание Якобиана для асимптотической ковариационной матрицы

Вернемся к примеру с выборкой из нормального распределения и для удобства запишем функцию правдоподобия для одного наблюдения:

$$\ln L(\mu, \sigma^2; X_i) = -0.5 \ln(2\pi) - \ln(\sigma) - \frac{(X_i - \mu)^2}{2\sigma^2}$$

Посчитаем частные производные:

$$\frac{\partial \ln L(\mu, \sigma^2; X_i)}{\partial \mu} = \frac{X_i - \mu}{\sigma^2}, \quad \frac{\partial \ln L(\mu, \sigma^2; X_i)}{\partial \sigma^2} = -\frac{1}{2\sigma^2} + \frac{(X_i - \mu)^2}{2\sigma^4}$$

Выпишем оценку Якобиана, заменяя истинные значения параметров их оценками:

$$J_* = \begin{bmatrix} \frac{X_1 - \hat{\mu}}{\hat{\sigma}^2} & \frac{(X_1 - \hat{\mu})^2}{2\hat{\sigma}^4} - \frac{1}{2\hat{\sigma}^2} \\ \vdots & \\ \frac{X_n - \hat{\mu}}{\hat{\sigma}^2} & \frac{(X_n - \hat{\mu})^2}{2\hat{\sigma}^4} - \frac{1}{2\hat{\sigma}^2} \end{bmatrix}$$

Метод максимального правдоподобия

Пример оценивание Гессиана для асимптотической ковариационной матрицы

Вернемся к примеру с выборкой из нормального распределения и для удобства запишем функцию правдоподобия для одного наблюдения:

$$\ln L(\mu, \sigma^2; X_i) = -0.5 \ln(2\pi) - \ln(\sigma) - \frac{(X_i - \mu)^2}{2\sigma^2}$$

Посчитаем вторые производные:

$$\frac{\partial^2 \ln L(\mu, \sigma^2; X_i)}{\partial^2 \mu} = -\frac{1}{\sigma^2}, \quad \frac{\partial^2 \ln L(\mu, \sigma^2; X_i)}{\partial^2 \sigma^2} = \frac{1}{2\sigma^4} - \frac{(X_i - \mu)^2}{\sigma^6}, \quad \frac{\partial^2 \ln L(\mu, \sigma^2; X_i)}{\partial \mu \partial \sigma^2} = \frac{\mu - X_i}{\sigma^4}$$

Выпишем оценку (скорректированного на знак) обратного Гессиана, заменяя истинные значения параметров и складывая вторые производные, посчитанные по отдельным наблюдениям:

$$H_* = - \begin{bmatrix} -\frac{n}{\hat{\sigma}^2} & \frac{\sum_{i=1}^n (\hat{\mu} - X_i)}{\hat{\sigma}^4} \\ \frac{\sum_{i=1}^n (\hat{\mu} - X_i)}{\hat{\sigma}^4} & \frac{n}{2\hat{\sigma}^4} - \frac{\sum_{i=1}^n (X_i - \hat{\mu})^2}{\hat{\sigma}^6} \end{bmatrix}^{-1} = - \begin{bmatrix} -\frac{n}{\hat{\sigma}^2} & 0 \\ 0 & -\frac{2n}{\hat{\sigma}^4} \end{bmatrix}^{-1} = \begin{bmatrix} \frac{\hat{\sigma}^2}{n} & 0 \\ 0 & \frac{\hat{\sigma}^2}{2n} \end{bmatrix}$$

- Рассмотрим функцию $g(\theta)$ и ММП оценку $\hat{\theta}$. В силу дельта метода оценка $g(\hat{\theta})$ будет асимптотически нормальной, причем:

$$As.E(g(\hat{\theta})) = g(\theta), \quad As.Cov(g(\hat{\theta})) = \nabla g(\theta)^T As.Cov(\hat{\theta}) \nabla g(\theta)$$

- Оценка асимптотической ковариационной матрицы будет иметь вид:

$$\widehat{As.Cov}(g(\hat{\theta})) = \nabla g(\hat{\theta})^T \widehat{As.Cov}(\hat{\theta}) \nabla g(\hat{\theta})$$

- Для тестирования гипотез и построения доверительных интервалов для $g(\theta)$ достаточно воспользоваться полученной оценкой асимптотической ковариационной матрицы.

Метод максимального правдоподобия

Пример применения дельта метода

- Вернемся к примеру с выборкой из нормального распределения и рассмотрим функцию:

$$g(\mu, \sigma^2) = \mu e^{2\sigma^2}$$

- Найдем градиент данной функции:

$$\nabla^T g(\mu, \sigma^2) = \left(e^{2\sigma^2}, 2\mu e^{2\sigma^2} \right)^T$$

- Выпишем выражение для оценки асимптотической ковариационной матрицы:

$$\widehat{As.Cov}(g(\hat{\mu}, \hat{\sigma}^2)) = \left(e^{2\hat{\sigma}^2}, 2\hat{\mu} e^{2\hat{\sigma}^2} \right) \widehat{As.Cov}(\hat{\mu}, \hat{\sigma}^2) \left(e^{2\hat{\sigma}^2}, 2\hat{\mu} e^{2\hat{\sigma}^2} \right)^T$$

- Если, например, асимптотическая ковариационная матрица была оценена методом обратного Гесса, то получаем:

$$\widehat{As.Cov}(g(\hat{\theta})) = \left(e^{2\hat{\sigma}^2}, 2\hat{\mu} e^{2\hat{\sigma}^2} \right) \begin{bmatrix} \frac{\hat{\sigma}^2}{n} & 0 \\ 0 & \frac{\hat{\sigma}^2}{2n} \end{bmatrix} \left(e^{2\hat{\sigma}^2}, 2\hat{\mu} e^{2\hat{\sigma}^2} \right)^T$$

Тестирование гипотез с помощью оценок максимального правдоподобия

Тестирование гипотезы о параметре

- Для тестирования гипотезы о параметре $H_0 : \theta_i = \theta_i^0$ сперва необходимо вычислить тестовую статистику:

$$T(X) = \frac{\hat{\theta}_i - \theta_i^0}{\sqrt{\widehat{As.Var}(\hat{\theta}_i)}}, \quad \widehat{As.Var}(\hat{\theta}_i) = \widehat{As.Cov}(\hat{\theta})_{i,i}$$

- Далее в силу асимптотической нормальности ММП оценок и теоремы Slutsky получаем, что:

$$T(X)|H_0 \xrightarrow{d} \mathcal{N}(0, 1)$$

- Поэтому p-value считается с помощью функции распределения стандартного нормального распределения.
- Например, в случае двухсторонней альтернативы $H_1 : \theta_i \neq \theta_i^0$ получаем:

$$\text{p-value} = 2 \min(\Phi(T(X)), 1 - \Phi(T(X)))$$

Тестирование гипотез с помощью оценок максимального правдоподобия

Тестирование гипотезы о функции от параметров

- Для тестирования гипотезы о функции от параметров $H_0 : g(\theta) = g^0$ сперва необходимо вычислить тестовую статистику:

$$T(X) = \frac{g(\hat{\theta}) - g^0}{\sqrt{\widehat{As.Var}(g(\hat{\theta}))}}, \quad \widehat{As.Var}(g(\hat{\theta})) = \widehat{As.Cov}(g(\hat{\theta}))_{i,i}$$

- Далее в силу дельта метода и теоремы Слущкого получаем, что:

$$T(X)|H_0 \xrightarrow{d} \mathcal{N}(0, 1)$$

- Поэтому p-value считается с помощью функции распределения стандартного нормального распределения.
- Например, в случае двухсторонней альтернативы $H_1 : \theta_i \neq \theta_i^0$ получаем:

$$\text{p-value} = 2 \min(\Phi(T(X)), 1 - \Phi(T(X)))$$

Тестирование гипотез с помощью оценок максимального правдоподобия

Пример, часть 1

- Логарифм зарплаты в обществе имеет нормальное распределение с математическим ожиданием μ и дисперсией σ^2 . Посчитанные по выборке из 200 человек выборочное среднее и выборочная дисперсия (не исправленная) логарифмов зарплат оказались равны 10 и 4 соответственно. Протестируем гипотезу о том, что дисперсия зарплаты случайно взятого индивида равняется 4.2 против альтернативы о том, что не равняется.
- Из условия получаем, что $\hat{\mu} = 10$ и $\hat{\sigma}^2 = 4$, откуда, методом обратного Гессiana, находим оценку асимптотической ковариационной матрицы, а из нее, асимптотической дисперсии:

$$\widehat{As.Cov}([\hat{\mu}, \hat{\sigma}^2]^T) = \begin{bmatrix} \frac{4}{200} & 0 \\ 0 & \frac{2 \times 4^2}{200} \end{bmatrix} = \begin{bmatrix} 0.02 & 0 \\ 0 & 0.016 \end{bmatrix} \Rightarrow \widehat{As.Var}(\hat{\sigma}^2) = 0.016$$

Тестируется гипотеза $H_0 : \sigma^2 = 4.2$, против альтернативы $H_1 : \sigma^2 \neq 4.2$.

$$T(X) = \frac{4 - 4.2}{\sqrt{0.016}} \approx -1.58 \Rightarrow \text{p-value} \approx 2 \min(\Phi(-1.58), 1 - \Phi(-1.58)) \approx 0.11$$

Поскольку $\text{p-value} > 0.1$, то нулевая гипотеза не отвергается даже на 10%-м уровне значимости.

Тестирование гипотез с помощью оценок максимального правдоподобия

Пример, часть 2

- В предыдущем примере протестируем гипотезу о том, что вероятность того, что логарифм зарплаты случайно взятого индивида меньше 12 равняется 0.8, против альтернативы о том, что не равняется.
- Выразим вероятность, о которой тестируется гипотеза, как функцию от параметров:

$$P(X_i < 12) = \Phi\left(\frac{12 - \mu}{\sigma}\right) = g(\mu, \sigma^2) \implies g(4, 10) \approx 0.84$$

Найдем градиент данной вероятности по параметрам:

$$\nabla g(\mu, \sigma^2) = \left(-\frac{\phi\left(\frac{12-\mu}{\sigma}\right)}{\sigma}, \frac{(\mu-12)\phi\left(\frac{12-\mu}{\sigma}\right)}{2\sigma^3} \right)^T \implies \nabla g(10, 4) \approx (-0.12, -0.03)^T$$

Применим дельта-метод:

$$\widehat{As. Var}(g(\hat{\mu}, \hat{\sigma}^2)) = (-0.12, -0.03) \begin{bmatrix} 0.02 & 0 \\ 0 & 0.016 \end{bmatrix} (-0.12, -0.03)^T \approx 0.0003024$$

Протестируем гипотезу $H_0 : P(X_i < 12) = 0.8$, против альтернативы $H_1 : P(X_i < 12) \neq 0.8$.

$$T(X) = \frac{0.84 - 0.8}{\sqrt{0.0003024}} \approx 2.3 \implies \text{p-value} \approx 2 \min(1 - \Phi(2.3), \Phi(2.3)) \approx 0.02$$

Тестирование гипотез с помощью оценок максимального правдоподобия

Тест отношения правдоподобий (LR-тест)

- Тестируется гипотеза об r ограничениях на параметры:

$$H_0 : \begin{cases} g_1(\theta) = 0 \\ \dots \\ g_r(\theta) = 0 \end{cases}, \quad g(\theta) = \begin{bmatrix} g_1(\theta) \\ \dots \\ g_r(\theta) \end{bmatrix}$$

- Для проведения теста отношения правдоподобий (LR-тест) необходимо сперва найти ММП оценки $\hat{\theta}$ без учета ограничений, то есть обычным образом.
- Затем находятся оценки с учетом ограничений, то есть за счет максимизации функции правдоподобия с учетом ограничений на параметры, накладываемых нулевой гипотезой $\hat{\theta}^R$.
- Далее, рассчитываются тестовая статистика и p-value:

$$T(X) = 2 \left(\ln L(\hat{\theta}) - \ln L(\hat{\theta}^R) \right), \quad T(X)|H_0 \xrightarrow{d} \chi^2(r) \implies \text{p-value} = 1 - F_{\chi^2(r)}(T(X))$$

Тестирование гипотез с помощью оценок максимального правдоподобия

Тест Вальда

- Тестируемая гипотеза, асимптотическое распределение тестовой статистики при верной нулевой гипотезе и способ расчета p-value аналогичны LR-тесту.
- Преимущество теста Вальда над LR-тестом заключается в том, что для расчета тестовой статистики достаточно оценить лишь модель без ограничений:

$$T(X) = g(\hat{\theta})^T \left(\widehat{As.Cov} \left(g(\hat{\theta}) \right) \right)^{-1} g(\hat{\theta})$$

- Данный тест удобно применять в случаях, когда на модель накладываются сложные ограничений, максимизация правдоподобия при условии которых является затруднительной технической задачей.

Тестирование гипотез с помощью оценок максимального правдоподобия

Тест множителей Лагранжа

- Тестируемая гипотеза, асимптотическое распределение тестовой статистики при верной нулевой гипотезе и способ расчета p-value аналогичны LR-тесту.
- Преимущество теста множителей Лагранжа (LM-тест) над LR-тестом и тестом Вальда заключается в том, что для расчета тестовой статистики достаточно оценить лишь модель с ограничениями:

$$T(X) = \nabla \ln L_F(\hat{\theta}^R; X)^T \left(\widehat{As.Cov}_F(\hat{\theta}^R) \right)^{-1} \nabla \ln L_F(\hat{\theta}^R; X)$$

Где под L_F и $\widehat{As.Cov}_F$ подразумевается, что мы рассчитываем логарифм правдоподобия и считаем выражение для оценки асимптотической ковариационной матрицы в точках, соответствующих оценкам ограниченной модели $\hat{\theta}^R$, но с использованием правдоподобия полной модели.

- Данный тест удобно применять в случаях, когда ограниченная модель оценивается проще, чем полная.