

# Микроэконометрика

## Спецификация моделей бинарного выбора

Потанин Богдан Станиславович

доцент, научный сотрудник, кандидат экономических наук

2022-2023

# Проблемы спецификации

## Список основных проблем

- Гетероскедастичность – дисперсии случайных ошибок могут зависеть от регрессоров.

# Проблемы спецификации

## Список основных проблем

- Гетероскедастичность – дисперсии случайных ошибок могут зависеть от регрессоров.
- Распределение случайной ошибки – может существенно отличаться от нормального или логистического.

# Проблемы спецификации

## Список основных проблем

- Гетероскедастичность – дисперсии случайных ошибок могут зависеть от регрессоров.
- Распределение случайной ошибки – может существенно отличаться от нормального или логистического.
- Панельные эффекты – при использовании панельных данных следует учитывать фиксированные или случайные эффекты.

# Проблемы спецификации

## Список основных проблем

- Гетероскедастичность – дисперсии случайных ошибок могут зависеть от регрессоров.
- Распределение случайной ошибки – может существенно отличаться от нормального или логистического.
- Панельные эффекты – при использовании панельных данных следует учитывать фиксированные или случайные эффекты.
- Случайные коэффициенты - влияние различных независимых переменных на вероятность может различаться для каждого наблюдения.

# Модели бинарного выбора с гетероскедастичностью

## Учет гетероскедастичности

- Предположим, что условная дисперсия случайных ошибок может зависеть от регрессоров, вследствие чего уравнение условной дисперсии принимает вид:

$$\text{Var}(\varepsilon_i | w_i) = [g(w_i \gamma)]^2$$

Где  $w_i \gamma$  – это линейный индекс уравнения дисперсии, в котором  $w_i$  является вектором регрессоров, а  $\gamma$  – вектором коэффициентов. При этом  $w_i$  не обязательно совпадает с регрессорами  $x_i$  уравнения латентной переменной  $y_i^*$ .

# Модели бинарного выбора с гетероскедастичностью

## Учет гетероскедастичности

- Предположим, что условная дисперсия случайных ошибок может зависеть от регрессоров, вследствие чего уравнение условной дисперсии принимает вид:

$$\text{Var}(\varepsilon_i | w_i) = [g(w_i \gamma)]^2$$

Где  $w_i \gamma$  – это линейный индекс уравнения дисперсии, в котором  $w_i$  является вектором регрессоров, а  $\gamma$  – вектором коэффициентов. При этом  $w_i$  не обязательно совпадает с регрессорами  $x_i$  уравнения латентной переменной  $y_i^*$ .

- В качестве  $g(\cdot)$  обычно полагают линейную функцию или экспоненту.

# Модели бинарного выбора с гетероскедастичностью

## Учет гетероскедастичности

- Предположим, что условная дисперсия случайных ошибок может зависеть от регрессоров, вследствие чего уравнение условной дисперсии принимает вид:

$$\text{Var}(\varepsilon_i | w_i) = [g(w_i \gamma)]^2$$

Где  $w_i \gamma$  – это линейный индекс уравнения дисперсии, в котором  $w_i$  является вектором регрессоров, а  $\gamma$  – вектором коэффициентов. При этом  $w_i$  не обязательно совпадает с регрессорами  $x_i$  уравнения латентной переменной  $y_i^*$ .

- В качестве  $g(\cdot)$  обычно полагают линейную функцию или экспоненту.
- Из соображений стандартизации обычно также полагают  $g(0) = 1$ .



# Модели бинарного выбора с гетероскедастичностью

## Учет гетероскедастичности

- Предположим, что условная дисперсия случайных ошибок может зависеть от регрессоров, вследствие чего уравнение условной дисперсии принимает вид:

$$\text{Var}(\varepsilon_i | w_i) = [g(w_i \gamma)]^2$$

Где  $w_i \gamma$  – это линейный индекс уравнения дисперсии, в котором  $w_i$  является вектором регрессоров, а  $\gamma$  – вектором коэффициентов. При этом  $w_i$  не обязательно совпадает с регрессорами  $x_i$  уравнения латентной переменной  $y_i^*$ .

- В качестве  $g(\cdot)$  обычно полагают линейную функцию или экспоненту.
- Из соображений стандартизации обычно также полагают  $g(0) = 1$ .
- При  $\gamma = (0, \dots, 0)^T$  получаем  $w_i \gamma = 0$ , откуда  $g(w_i \gamma) = g(0) = 1$ , а значит дисперсия не зависит от  $w_i$ . Поэтому тестирование гетероскедастичности эквивалентно тестированию гипотезы  $H_0 : \gamma = (0, \dots, 0)^T$ . Ее можно протестировать при помощи LR-теста, LM-теста или теста Вальда.

# Модели бинарного выбора с гетероскедастичностью

## Учет гетероскедастичности

- Предположим, что условная дисперсия случайных ошибок может зависеть от регрессоров, вследствие чего уравнение условной дисперсии принимает вид:

$$\text{Var}(\varepsilon_i | w_i) = [g(w_i \gamma)]^2$$

Где  $w_i \gamma$  – это линейный индекс уравнения дисперсии, в котором  $w_i$  является вектором регрессоров, а  $\gamma$  – вектором коэффициентов. При этом  $w_i$  не обязательно совпадает с регрессорами  $x_i$  уравнения латентной переменной  $y_i^*$ .

- В качестве  $g(\cdot)$  обычно полагают линейную функцию или экспоненту.
- Из соображений стандартизации обычно также полагают  $g(0) = 1$ .
- При  $\gamma = (0, \dots, 0)^T$  получаем  $w_i \gamma = 0$ , откуда  $g(w_i \gamma) = g(0) = 1$ , а значит дисперсия не зависит от  $w_i$ . Поэтому тестирование гетероскедастичности эквивалентно тестированию гипотезы  $H_0 : \gamma = (0, \dots, 0)^T$ . Ее можно протестировать при помощи LR-теста, LM-теста или теста Вальда.
- Отсутствие учета гетероскедастичности может привести к несостоятельности оценок вследствие неверной спецификации функции правдоподобия.

# Модели бинарного выбора с гетероскедастичностью

## Вероятности и предельные эффекты

- Для простоты далее будем рассматривать гетероскедастичную пробит модель и предположим  $g(t) > 0$  при любом  $t \in R$ .

# Модели бинарного выбора с гетероскедастичностью

## Вероятности и предельные эффекты

- Для простоты далее будем рассматривать гетероскедастичную пробит модель и предположим  $g(t) > 0$  при любом  $t \in R$ .
- С учетом гетероскедастичности получаем выражение для условной вероятности:

$$P(y_i = 1 | x_i, w_i) = P(\varepsilon_i \geq -x_i\beta) = 1 - \Phi\left(\frac{-x_i\beta}{g(w_i\gamma)}\right) = \Phi\left(\frac{x_i\beta}{g(w_i\gamma)}\right)$$

# Модели бинарного выбора с гетероскедастичностью

## Вероятности и предельные эффекты

- Для простоты далее будем рассматривать гетероскедастичную пробит модель и предположим  $g(t) > 0$  при любом  $t \in R$ .
- С учетом гетероскедастичности получаем выражение для условной вероятности:

$$P(y_i = 1 | x_i, w_i) = P(\varepsilon_i \geq -x_i\beta) = 1 - \Phi\left(\frac{-x_i\beta}{g(w_i\gamma)}\right) = \Phi\left(\frac{x_i\beta}{g(w_i\gamma)}\right)$$

- Рассмотрим непрерывную переменную  $v_i$ , которая входит и в  $x_i$  и в  $w_i$  с коэффициентами  $\beta_v$  и  $\gamma_v$  соответственно, тогда:

$$\frac{\partial P(y_i = 1 | x_i, w_i)}{\partial v_i} = \phi\left(\frac{x_i\beta}{g(w_i\gamma)}\right) \frac{\beta_v g(w_i\gamma) - \gamma_v g'(w_i\gamma) x_i\beta}{g(w_i\gamma)^2}$$

Где  $g'(w_i\gamma)$  является производной  $g(\cdot)$  в точке  $w_i\gamma$ .

# Модели бинарного выбора с гетероскедастичностью

## Вероятности и предельные эффекты

- Для простоты далее будем рассматривать гетероскедастичную пробит модель и предположим  $g(t) > 0$  при любом  $t \in R$ .
- С учетом гетероскедастичности получаем выражение для условной вероятности:

$$P(y_i = 1|x_i, w_i) = P(\varepsilon_i \geq -x_i\beta) = 1 - \Phi\left(\frac{-x_i\beta}{g(w_i\gamma)}\right) = \Phi\left(\frac{x_i\beta}{g(w_i\gamma)}\right)$$

- Рассмотрим непрерывную переменную  $v_i$ , которая входит и в  $x_i$  и в  $w_i$  с коэффициентами  $\beta_v$  и  $\gamma_v$  соответственно, тогда:

$$\frac{\partial P(y_i = 1|x_i, w_i)}{\partial v_i} = \phi\left(\frac{x_i\beta}{g(w_i\gamma)}\right) \frac{\beta_v g(w_i\gamma) - \gamma_v g'(w_i\gamma)x_i\beta}{g(w_i\gamma)^2}$$

Где  $g'(w_i\gamma)$  является производной  $g(\cdot)$  в точке  $w_i\gamma$ .

- Для того, чтобы получить формулу предельного эффекта для переменной, входящей лишь в  $x_i$  или  $w_i$ , достаточно предположить равенство нулю  $\beta_v$  или  $\gamma_v$  соответственно.

# Модели бинарного выбора с гетероскедастичностью

## Оценивание

- По аналогии с классическими моделями бинарного выбора оценивание осуществляется с помощью метода максимального правдоподобия. При этом функция правдоподобия имеет вид:

$$L(\beta, \gamma; y|X, W) = \prod_{i:y_i=1} \Phi\left(\frac{x_i\beta}{g(w_i\gamma)}\right) \prod_{i:y_i=0} 1 - \Phi\left(\frac{x_i\beta}{g(w_i\gamma)}\right)$$

# Модели бинарного выбора с гетероскедастичностью

## Оценивание

- По аналогии с классическими моделями бинарного выбора оценивание осуществляется с помощью метода максимального правдоподобия. При этом функция правдоподобия имеет вид:

$$L(\beta, \gamma; y|X, W) = \prod_{i:y_i=1} \Phi\left(\frac{x_i\beta}{g(w_i\gamma)}\right) \prod_{i:y_i=0} 1 - \Phi\left(\frac{x_i\beta}{g(w_i\gamma)}\right)$$

- При некоторых формах  $w_i\gamma$  регрессоры  $w_i$  не должны включать константу. Например, при использовании наиболее популярной спецификации  $g(w_i\gamma) = e^{\gamma_0 + w_i\gamma}$  имеем:

$$P(y_i = 1|x_i, w_i) = \Phi\left(\frac{x_i\beta}{e^{\gamma_0 + w_i\gamma}}\right) = \Phi\left(\frac{x_i(\beta/e^{\gamma_0})}{e^{w_i\gamma}}\right) = \Phi\left(\frac{x_i\beta^*}{e^{w_i\gamma}}\right), \text{ где } \beta^* = \beta/e^{\gamma_0}$$



# Модели бинарного выбора с гетероскедастичностью

## Оценивание

- По аналогии с классическими моделями бинарного выбора оценивание осуществляется с помощью метода максимального правдоподобия. При этом функция правдоподобия имеет вид:

$$L(\beta, \gamma; y|X, W) = \prod_{i: y_i=1} \Phi\left(\frac{x_i\beta}{g(w_i\gamma)}\right) \prod_{i: y_i=0} 1 - \Phi\left(\frac{x_i\beta}{g(w_i\gamma)}\right)$$

- При некоторых формах  $w_i\gamma$  регрессоры  $w_i$  не должны включать константу. Например, при использовании наиболее популярной спецификации  $g(w_i\gamma) = e^{\gamma_0 + w_i\gamma}$  имеем:

$$P(y_i = 1|x_i, w_i) = \Phi\left(\frac{x_i\beta}{e^{\gamma_0 + w_i\gamma}}\right) = \Phi\left(\frac{x_i(\beta/e^{\gamma_0})}{e^{w_i\gamma}}\right) = \Phi\left(\frac{x_i\beta^*}{e^{w_i\gamma}}\right), \text{ где } \beta^* = \beta/e^{\gamma_0}$$

В результате мы можем заменить  $\beta/e^{\gamma_0}$  на  $\beta^*$  при максимизации функции правдоподобия. Но каждому значению  $\beta^*$  соответствует бесконечное число комбинаций параметров  $\beta$  и  $\gamma_0$ . В результате  $\beta$  и  $\gamma_0$  оказываются неидентифицируемы, а функция правдоподобия – имеет бесконечное число максимумов при наличии  $\gamma_0$ . Во избежание данной проблемы без потери общности полагают  $\gamma_0 = 0$ .

# Модели бинарного выбора с гетероскедастичностью

## Тестирование гетероскедастичности при помощи LM-теста, часть 1

- Рассмотрим тестирование гипотезы об отсутствии гетероскедастичности  $H_0 : \gamma = (0, \dots, 0)^T$  с помощью LM-теста.

# Модели бинарного выбора с гетероскедастичностью

## Тестирование гетероскедастичности при помощи LM-теста, часть 1

- Рассмотрим тестирование гипотезы об отсутствии гетероскедастичности  $H_0 : \gamma = (0, \dots, 0)^T$  с помощью LM-теста.
- Производная логарифма правдоподобия по  $\gamma_k$  имеет вид:

$$\frac{\partial \ln L}{\partial \gamma_k} = \sum_{i: y_i=1} \frac{\phi\left(\frac{x_i \beta}{g(w_i \gamma)}\right)}{\Phi\left(\frac{x_i \beta}{g(w_i \gamma)}\right)} \frac{-w_{ki} g'(w_i \gamma) x_i \beta}{g(w_i \gamma)^2} + \sum_{i: y_i=0} \frac{\phi\left(\frac{x_i \beta}{g(w_i \gamma)}\right)}{1 - \Phi\left(\frac{x_i \beta}{g(w_i \gamma)}\right)} \frac{x_{wi} g'(w_i \gamma) x_i \beta}{g(w_i \gamma)^2}$$

# Модели бинарного выбора с гетероскедастичностью

## Тестирование гетероскедастичности при помощи LM-теста, часть 1

- Рассмотрим тестирование гипотезы об отсутствии гетероскедастичности  $H_0 : \gamma = (0, \dots, 0)^T$  с помощью LM-теста.
- Производная логарифма правдоподобия по  $\gamma_k$  имеет вид:

$$\frac{\partial \ln L}{\partial \gamma_k} = \sum_{i:y_i=1} \frac{\phi\left(\frac{x_i\beta}{g(w_i\gamma)}\right)}{\Phi\left(\frac{x_i\beta}{g(w_i\gamma)}\right)} \frac{-w_{ki}g'(w_i\gamma)x_i\beta}{g(w_i\gamma)^2} + \sum_{i:y_i=0} \frac{\phi\left(\frac{x_i\beta}{g(w_i\gamma)}\right)}{1 - \Phi\left(\frac{x_i\beta}{g(w_i\gamma)}\right)} \frac{x_{wi}g'(w_i\gamma)x_i\beta}{g(w_i\gamma)^2}$$

- Для ограниченной модели  $\gamma = (0, \dots, 0)^T$  получаем:

$$\frac{\partial \ln L(\beta, 0, \dots, 0; y|X, W)}{\partial \gamma_k} = \sum_{i:y_i=1} \frac{\phi(x_i\beta)}{\Phi(x_i\beta)} (-w_{ki}g'(0)x_i\beta) + \sum_{i:y_i=0} \frac{\phi(x_i\beta)}{1 - \Phi(x_i\beta)} w_{ki}g'(0)x_i\beta =$$

# Модели бинарного выбора с гетероскедастичностью

## Тестирование гетероскедастичности при помощи LM-теста, часть 1

- Рассмотрим тестирование гипотезы об отсутствии гетероскедастичности  $H_0 : \gamma = (0, \dots, 0)^T$  с помощью LM-теста.
- Производная логарифма правдоподобия по  $\gamma_k$  имеет вид:

$$\frac{\partial \ln L}{\partial \gamma_k} = \sum_{i:y_i=1} \frac{\phi\left(\frac{x_i\beta}{g(w_i\gamma)}\right)}{\Phi\left(\frac{x_i\beta}{g(w_i\gamma)}\right)} \frac{-w_{ki}g'(w_i\gamma)x_i\beta}{g(w_i\gamma)^2} + \sum_{i:y_i=0} \frac{\phi\left(\frac{x_i\beta}{g(w_i\gamma)}\right)}{1 - \Phi\left(\frac{x_i\beta}{g(w_i\gamma)}\right)} \frac{x_{wi}g'(w_i\gamma)x_i\beta}{g(w_i\gamma)^2}$$

- Для ограниченной модели  $\gamma = (0, \dots, 0)^T$  получаем:

$$\begin{aligned} \frac{\partial \ln L(\beta, 0, \dots, 0; y|X, W)}{\partial \gamma_k} &= \sum_{i:y_i=1} \frac{\phi(x_i\beta)}{\Phi(x_i\beta)} (-w_{ki}g'(0)x_i\beta) + \sum_{i:y_i=0} \frac{\phi(x_i\beta)}{1 - \Phi(x_i\beta)} w_{ki}g'(0)x_i\beta = \\ &= g'(0) \sum_{i=1}^n \frac{\phi(x_i\beta)}{\Phi((2y_i - 1)x_i\beta)} w_{ki} (1 - 2y_i) x_i\beta \end{aligned}$$

# Модели бинарного выбора с гетероскедастичностью

## Тестирование гетероскедастичности при помощи LM-теста, часть 1

- Рассмотрим тестирование гипотезы об отсутствии гетероскедастичности  $H_0 : \gamma = (0, \dots, 0)^T$  с помощью LM-теста.
- Производная логарифма правдоподобия по  $\gamma_k$  имеет вид:

$$\frac{\partial \ln L}{\partial \gamma_k} = \sum_{i:y_i=1} \frac{\phi\left(\frac{x_i\beta}{g(w_i\gamma)}\right)}{\Phi\left(\frac{x_i\beta}{g(w_i\gamma)}\right)} \frac{-w_{ki}g'(w_i\gamma)x_i\beta}{g(w_i\gamma)^2} + \sum_{i:y_i=0} \frac{\phi\left(\frac{x_i\beta}{g(w_i\gamma)}\right)}{1 - \Phi\left(\frac{x_i\beta}{g(w_i\gamma)}\right)} \frac{x_{wi}g'(w_i\gamma)x_i\beta}{g(w_i\gamma)^2}$$

- Для ограниченной модели  $\gamma = (0, \dots, 0)^T$  получаем:

$$\begin{aligned} \frac{\partial \ln L(\beta, 0, \dots, 0; y|X, W)}{\partial \gamma_k} &= \sum_{i:y_i=1} \frac{\phi(x_i\beta)}{\Phi(x_i\beta)} (-w_{ki}g'(0)x_i\beta) + \sum_{i:y_i=0} \frac{\phi(x_i\beta)}{1 - \Phi(x_i\beta)} w_{ki}g'(0)x_i\beta = \\ &= g'(0) \sum_{i=1}^n \frac{\phi(x_i\beta)}{\Phi((2y_i - 1)x_i\beta)} w_{ki} (1 - 2y_i) x_i\beta \end{aligned}$$

- Поскольку частные производные отличаются лишь множителями  $x_{wi}$ , то градиент принимает вид:

$$\nabla_{\gamma} \ln L(\beta, 0, \dots, 0; y|X, W) = g'(0) \sum_{i=1}^n \frac{\phi(x_i\beta)}{\Phi((2y_i - 1)x_i\beta)} w_i^T (1 - 2y_i) x_i\beta$$

# Модели бинарного выбора с гетероскедастичностью

## Тестирование гетероскедастичности при помощи LM-теста, часть 2

- По аналогии нетрудно показать, что:

$$\nabla_{\beta} \ln L(\beta, 0, \dots, 0; y|X, W) = g'(0) \sum_{i=1}^n \frac{\phi(x_i \beta)}{\Phi((2y_i - 1)x_i \beta)} x_i^T (2y_i - 1)$$

# Модели бинарного выбора с гетероскедастичностью

## Тестирование гетероскедастичности при помощи LM-теста, часть 2

- По аналогии нетрудно показать, что:

$$\nabla_{\beta} \ln L(\beta, 0, \dots, 0; y|X, W) = g'(0) \sum_{i=1}^n \frac{\phi(x_i \beta)}{\Phi((2y_i - 1)x_i \beta)} x_i^T (2y_i - 1)$$

- В результате получаем:

$$\nabla \ln L_F = \begin{bmatrix} \nabla_{\beta} L_F \\ \nabla_{\gamma} L_F \end{bmatrix}, \text{ где } \ln L_F = \ln L(\hat{\beta}, 0, \dots, 0; y|X, W),$$

где  $\hat{\beta}$  является оценкой обычной (ограниченной) пробит модели, откуда  $\nabla_{\beta} L_F = (0, \dots, 0)$ .



# Модели бинарного выбора с гетероскедастичностью

## Тестирование гетероскедастичности при помощи LM-теста, часть 2

- По аналогии нетрудно показать, что:

$$\nabla_{\beta} \ln L(\beta, 0, \dots, 0; y|X, W) = g'(0) \sum_{i=1}^n \frac{\phi(x_i \beta)}{\Phi((2y_i - 1)x_i \beta)} x_i^T (2y_i - 1)$$

- В результате получаем:

$$\nabla \ln L_F = \begin{bmatrix} \nabla_{\beta} L_F \\ \nabla_{\gamma} L_F \end{bmatrix}, \text{ где } \ln L_F = \ln L(\hat{\beta}, 0, \dots, 0; y|X, W),$$

где  $\hat{\beta}$  является оценкой обычной (ограниченной) пробит модели, откуда  $\nabla_{\beta} L_F = (0, \dots, 0)$ .

- В итоге предполагая  $g'(0) \neq 0$  нетрудно записать тестовую статистику LM-теста в виде (для расчета  $\widehat{As.Cov}_F$  воспользуемся произведением якобианов), при котором она не зависит от  $g'(0)$ :

$$(\nabla \ln L_F)^T \left( J(L_F)^T J(L_F) \right)^{-1} \ln L_F =$$

# Модели бинарного выбора с гетероскедастичностью

## Тестирование гетероскедастичности при помощи LM-теста, часть 2

- По аналогии нетрудно показать, что:

$$\nabla_{\beta} \ln L(\beta, 0, \dots, 0; y|X, W) = g'(0) \sum_{i=1}^n \frac{\phi(x_i \beta)}{\Phi((2y_i - 1)x_i \beta)} x_i^T (2y_i - 1)$$

- В результате получаем:

$$\nabla \ln L_F = \begin{bmatrix} \nabla_{\beta} L_F \\ \nabla_{\gamma} L_F \end{bmatrix}, \text{ где } \ln L_F = \ln L(\hat{\beta}, 0, \dots, 0; y|X, W),$$

где  $\hat{\beta}$  является оценкой обычной (ограниченной) пробит модели, откуда  $\nabla_{\beta} L_F = (0, \dots, 0)$ .

- В итоге предполагая  $g'(0) \neq 0$  нетрудно записать тестовую статистику LM-теста в виде (для расчета  $\widehat{As.Cov}_F$  воспользуемся произведением якобианов), при котором она не зависит от  $g'(0)$ :

$$(\nabla \ln L_F)^T \left( J(L_F)^T J(L_F) \right)^{-1} \ln L_F = (\ln L_F / g'(0))^T \left( \left[ J(L_F)^T / g'(0) \right] \left[ J(L_F) / g'(0) \right] \right)^{-1} \ln L_F / g'(0)$$

# Модели бинарного выбора с гетероскедастичностью

## Тестирование гетероскедастичности при помощи LM-теста, часть 2

- По аналогии нетрудно показать, что:

$$\nabla_{\beta} \ln L(\beta, 0, \dots, 0; y|X, W) = g'(0) \sum_{i=1}^n \frac{\phi(x_i \beta)}{\Phi((2y_i - 1)x_i \beta)} x_i^T (2y_i - 1)$$

- В результате получаем:

$$\nabla \ln L_F = \begin{bmatrix} \nabla_{\beta} L_F \\ \nabla_{\gamma} L_F \end{bmatrix}, \text{ где } \ln L_F = \ln L(\hat{\beta}, 0, \dots, 0; y|X, W),$$

где  $\hat{\beta}$  является оценкой обычной (ограниченной) пробит модели, откуда  $\nabla_{\beta} L_F = (0, \dots, 0)$ .

- В итоге предполагая  $g'(0) \neq 0$  нетрудно записать тестовую статистику LM-теста в виде (для расчета  $\widehat{As.Cov}_F$  воспользуемся произведением якобианов), при котором она не зависит от  $g'(0)$ :

$$(\nabla \ln L_F)^T \left( J(L_F)^T J(L_F) \right)^{-1} \ln L_F = (\ln L_F / g'(0))^T \left( \left[ J(L_F)^T / g'(0) \right] \left[ J(L_F) / g'(0) \right] \right)^{-1} \ln L_F / g'(0)$$

- Таким образом, значение тестовой статистики не зависит от формы функции  $g(\cdot)$ . Следовательно, благодаря LM-тесту мы тестируем гипотезу об отсутствии гетероскедастичности против альтернативы о том, что она определяется широким классом функций вида  $g(\cdot)$ .

# Тестирование гипотезы о распределении случайной ошибки

## Общая идея

- Некорректная спецификация распределении случайной ошибки  $\varepsilon_i$  в модели бинарного выбора может привести к несостоятельности оценок.

# Тестирование гипотезы о распределении случайной ошибки

## Общая идея

- Некорректная спецификация распределении случайной ошибки  $\varepsilon_i$  в модели бинарного выбора может привести к несостоятельности оценок.
- На практике распределение случайной ошибки  $\varepsilon_i$  может отличаться от нормального или логистического. Для простоты рассмотрим подходы к тестированию гипотезы о стандартном нормальном распределении случайных ошибок  $\varepsilon_i \sim \mathcal{N}(0, 1)$ .

# Тестирование гипотезы о распределении случайной ошибки

## Общая идея

- Некорректная спецификация распределении случайной ошибки  $\varepsilon_i$  в модели бинарного выбора может привести к несостоятельности оценок.
- На практике распределение случайной ошибки  $\varepsilon_i$  может отличаться от нормального или логистического. Для простоты рассмотрим подходы к тестированию гипотезы о стандартном нормальном распределении случайных ошибок  $\varepsilon_i \sim \mathcal{N}(0, 1)$ .
- Предполагается, что случайные ошибки в полной модели распределены в соответствии с некоторым распределением  $\Theta$  с вектором параметров  $\theta$ , то есть в полной модели  $\varepsilon_i \sim \Theta(\theta)$ . Кроме того, при некотором  $\theta = \theta^0$  распределение  $\Theta$  совпадает со стандартным нормальным  $\mathcal{N}(0, 1)$ , то есть  $\Theta(\theta^0) = \mathcal{N}(0, 1)$ . В результате гипотеза о нормальности принимает параметрический вид  $H_0 : \theta = \theta_0$ .

# Тестирование гипотезы о распределении случайной ошибки

## Общая идея

- Некорректная спецификация распределении случайной ошибки  $\varepsilon_i$  в модели бинарного выбора может привести к несостоятельности оценок.
- На практике распределение случайной ошибки  $\varepsilon_i$  может отличаться от нормального или логистического. Для простоты рассмотрим подходы к тестированию гипотезы о стандартном нормальном распределении случайных ошибок  $\varepsilon_i \sim \mathcal{N}(0, 1)$ .
- Предполагается, что случайные ошибки в полной модели распределены в соответствии с некоторым распределением  $\Theta$  с вектором параметров  $\theta$ , то есть в полной модели  $\varepsilon_i \sim \Theta(\theta)$ . Кроме того, при некотором  $\theta = \theta^0$  распределение  $\Theta$  совпадает со стандартным нормальным  $\mathcal{N}(0, 1)$ , то есть  $\Theta(\theta^0) = \mathcal{N}(0, 1)$ . В результате гипотеза о нормальности принимает параметрический вид  $H_0 : \theta = \theta_0$ .
- Далее полная модель может быть оценена при помощи ММП, где  $\theta$  выступает в качестве дополнительного вектора оцениваемых (вместе с  $\beta$ ) параметров. Для тестирования гипотезы можно воспользоваться LR-тестом, LM-тестом или тестом Вальда. Обычно наиболее удобным является LM-тест, поскольку позволяет не оценивать полную модель, что при сложных формах  $\Theta$  бывает технически затруднительным.

# Тестирование гипотезы о распределении случайной ошибки

## Тестирование гипотезы о нормальном распределении

- В качестве альтернативы стандартному нормальному распределению рассмотрим распределение из семейства кривых Пирсона с параметрами  $\theta_1$  и  $\theta_2$ , функция распределения которого имеет вид:

$$\Phi(t + \theta_1 t^2 + \theta_2 t^3)$$



# Тестирование гипотезы о распределении случайной ошибки

## Тестирование гипотезы о нормальном распределении

- В качестве альтернативы стандартному нормальному распределению рассмотрим распределение из семейства кривых Пирсона с параметрами  $\theta_1$  и  $\theta_2$ , функция распределения которого имеет вид:

$$\Phi(t + \theta_1 t^2 + \theta_2 t^3)$$

- При  $\theta_1 = \theta_2 = 0$  данное распределение совпадает со стандартным нормальным, поэтому тестирование гипотезы о корректности применения пробит модели эквивалентно проверке параметрической гипотезы  $H_0 : \theta_1 = \theta_2 = 0$ .

# Тестирование гипотезы о распределении случайной ошибки

## Тестирование гипотезы о нормальном распределении

- В качестве альтернативы стандартному нормальному распределению рассмотрим распределение из семейства кривых Пирсона с параметрами  $\theta_1$  и  $\theta_2$ , функция распределения которого имеет вид:

$$\Phi(t + \theta_1 t^2 + \theta_2 t^3)$$

- При  $\theta_1 = \theta_2 = 0$  данное распределение совпадает со стандартным нормальным, поэтому тестирование гипотезы о корректности применения пробит модели эквивалентно проверке параметрической гипотезы  $H_0 : \theta_1 = \theta_2 = 0$ .
- Оценивание полной модели предполагает максимизацию функции правдоподобия по параметрам  $\beta$ ,  $\theta_1$  и  $\theta_2$  с использованием  $\Phi(x_i\beta + \theta_1 x_i\beta^2 + \theta_2 x_i\beta^3)$  вместо  $\Phi(x_i\beta)$ .

# Тестирование гипотезы о распределении случайной ошибки

## Тестирование гипотезы о нормальном распределении

- В качестве альтернативы стандартному нормальному распределению рассмотрим распределение из семейства кривых Пирсона с параметрами  $\theta_1$  и  $\theta_2$ , функция распределения которого имеет вид:

$$\Phi(t + \theta_1 t^2 + \theta_2 t^3)$$

- При  $\theta_1 = \theta_2 = 0$  данное распределение совпадает со стандартным нормальным, поэтому тестирование гипотезы о корректности применения пробит модели эквивалентно проверке параметрической гипотезы  $H_0 : \theta_1 = \theta_2 = 0$ .
- Оценивание полной модели предполагает максимизацию функции правдоподобия по параметрам  $\beta$ ,  $\theta_1$  и  $\theta_2$  с использованием  $\Phi(x_i\beta + \theta_1 x_i\beta^2 + \theta_2 x_i\beta^3)$  вместо  $\Phi(x_i\beta)$ .
- Поскольку оценивание полной модели является достаточно затруднительной технической задачей, то для проверки гипотезы о стандартном нормальном распределении случайной ошибки предпочтительно воспользоваться LM-тестом.

# Тестирование гипотезы о распределении случайной ошибки

## Тестирование гипотезы о нормальном распределении

- В качестве альтернативы стандартному нормальному распределению рассмотрим распределение из семейства кривых Пирсона с параметрами  $\theta_1$  и  $\theta_2$ , функция распределения которого имеет вид:

$$\Phi(t + \theta_1 t^2 + \theta_2 t^3)$$

- При  $\theta_1 = \theta_2 = 0$  данное распределение совпадает со стандартным нормальным, поэтому тестирование гипотезы о корректности применения пробит модели эквивалентно проверке параметрической гипотезы  $H_0 : \theta_1 = \theta_2 = 0$ .
- Оценивание полной модели предполагает максимизацию функции правдоподобия по параметрам  $\beta$ ,  $\theta_1$  и  $\theta_2$  с использованием  $\Phi(x_i\beta + \theta_1 x_i\beta^2 + \theta_2 x_i\beta^3)$  вместо  $\Phi(x_i\beta)$ .
- Поскольку оценивание полной модели является достаточно затруднительной технической задачей, то для проверки гипотезы о стандартном нормальном распределении случайной ошибки предпочтительно воспользоваться LM-тестом.
- Недостаток данного подхода заключается в рассмотрении достаточно узкого класса распределений в качестве альтернативы стандартному нормальному.

# Полупараметрические модели бинарного выбора

## Распределение Галланта и Нички

- Галлант и Ничка предложили распределение со следующими функцией плотности:

$$f_{GN}(t; \theta) = \frac{(1 + \theta_1 t + \dots + \theta_K t^K)^2}{\sum_{i=0}^K \sum_{j=0}^K \theta_i \theta_j M(i+j)} \phi(t),$$

где через  $M(k)$  обозначается  $k$ -й начальный момент стандартного нормального распределения.

# Полупараметрические модели бинарного выбора

## Распределение Галланта и Нички

- Галлант и Ничка предложили распределение со следующими функцией плотности:

$$f_{GN}(t; \theta) = \frac{(1 + \theta_1 t + \dots + \theta_K t^K)^2}{\sum_{i=0}^K \sum_{j=0}^K \theta_i \theta_j M(i+j)} \phi(t),$$

где через  $M(k)$  обозначается  $k$ -й начальный момент стандартного нормального распределения.

- При  $\theta_1 = \dots = \theta_K = 0$  данное распределение совпадает со стандартным нормальным, поэтому тестирование гипотезы о нормальности эквивалентно тестированию соблюдения данного ограничения на параметры.

# Полупараметрические модели бинарного выбора

## Распределение Галланта и Нички

- Галлант и Ничка предложили распределение со следующими функцией плотности:

$$f_{GN}(t; \theta) = \frac{(1 + \theta_1 t + \dots + \theta_K t^K)^2}{\sum_{i=0}^K \sum_{j=0}^K \theta_i \theta_j M(i+j)} \phi(t),$$

где через  $M(k)$  обозначается  $k$ -й начальный момент стандартного нормального распределения.

- При  $\theta_1 = \dots = \theta_K = 0$  данное распределение совпадает со стандартным нормальным, поэтому тестирование гипотезы о нормальности эквивалентно тестированию соблюдения данного ограничения на параметры.
- За счет полинома в числителе данное распределение может аппроксимировать широкий класс распределений. Чем больше  $K$ , тем более широкий класс распределений можно достаточно точно аппроксимировать.

# Полупараметрические модели бинарного выбора

## Распределение Галланта и Нички

- Галлант и Ничка предложили распределение со следующими функцией плотности:

$$f_{GN}(t; \theta) = \frac{(1 + \theta_1 t + \dots + \theta_K t^K)^2}{\sum_{i=0}^K \sum_{j=0}^K \theta_i \theta_j M(i+j)} \phi(t),$$

где через  $M(k)$  обозначается  $k$ -й начальный момент стандартного нормального распределения.

- При  $\theta_1 = \dots = \theta_K = 0$  данное распределение совпадает со стандартным нормальным, поэтому тестирование гипотезы о нормальности эквивалентно тестированию соблюдения данного ограничения на параметры.
- За счет полинома в числителе данное распределение может аппроксимировать широкий класс распределений. Чем больше  $K$ , тем более широкий класс распределений можно достаточно точно аппроксимировать.
- Функция распределения и моменты распределения Галланта и Нички считаются как:

$$F_{GN}(t; \theta) = \frac{\sum_{i=0}^K \sum_{j=0}^K \theta_i \theta_j M(i+j; t)}{\sum_{i=0}^K \sum_{j=0}^K \theta_i \theta_j M(i+j)} \Phi(t), \quad M_{GN}(k; \theta) = \frac{\sum_{i=0}^K \sum_{j=0}^K \theta_i \theta_j M(i+j+k)}{\sum_{i=0}^K \sum_{j=0}^K \theta_i \theta_j M(i+j)},$$

где через  $M(k; t)$  обозначается  $k$ -й начальный момент стандартного нормального распределения, усеченного сверху в точке  $t$ .



# Полупараметрические модели бинарного выбора

## Стандартизация распределения Галланта и Нички

- Распределение Галланта и Нички часто используют для того, что аппроксимировать неизвестное распределение случайной ошибки.

# Полупараметрические модели бинарного выбора

## Стандартизация распределения Галланта и Нички

- Распределение Галланта и Нички часто используют для того, что аппроксимировать неизвестное распределение случайной ошибки.
- При различных параметрах  $\theta$  данное распределение имеет различные математическое ожидание и дисперсию, что может вызвать проблемы с идентифицируемостью  $\beta$  в моделях бинарного выбора.

# Полупараметрические модели бинарного выбора

## Стандартизация распределения Галланта и Нички

- Распределение Галланта и Нички часто используют для того, что аппроксимировать неизвестное распределение случайной ошибки.
- При различных параметрах  $\theta$  данное распределение имеет различные математическое ожидание и дисперсию, что может вызвать проблемы с идентифицируемостью  $\beta$  в моделях бинарного выбора.
- Во избежание данных проблем распределение Галланта и Нички удобно стандартизировать к нулевому математическому ожиданию и единичной дисперсии.

# Полупараметрические модели бинарного выбора

## Стандартизация распределения Галланта и Нички

- Распределение Галланта и Нички часто используют для того, что аппроксимировать неизвестное распределение случайной ошибки.
- При различных параметрах  $\theta$  данное распределение имеет различные математическое ожидание и дисперсию, что может вызвать проблемы с идентифицируемостью  $\beta$  в моделях бинарного выбора.
- Во избежание данных проблем распределение Галланта и Нички удобно стандартизировать к нулевому математическому ожиданию и единичной дисперсии.
- Обозначим через  $Z$  случайную величину, имеющую распределение Галланта и Нички с вектором параметров  $\theta$ . Тогда функция распределения случайной величины  $Z^* = \frac{Z - E(Z)}{\sqrt{Var(Z)}}$ , имеющей стандартизированное распределение Галланта и Нички  $GN^*$ , будет иметь вид:

$$F_{GN^*}(t; \theta) = F_{Z^*}(t; \theta) = P(Z^* \leq t) = P\left(\frac{Z - E(Z)}{\sqrt{Var(Z)}} \leq t\right) =$$

# Полупараметрические модели бинарного выбора

## Стандартизация распределения Галланта и Нички

- Распределение Галланта и Нички часто используют для того, что аппроксимировать неизвестное распределение случайной ошибки.
- При различных параметрах  $\theta$  данное распределение имеет различные математическое ожидание и дисперсию, что может вызвать проблемы с идентифицируемостью  $\beta$  в моделях бинарного выбора.
- Во избежание данных проблем распределение Галланта и Нички удобно стандартизировать к нулевому математическому ожиданию и единичной дисперсии.
- Обозначим через  $Z$  случайную величину, имеющую распределение Галланта и Нички с вектором параметров  $\theta$ . Тогда функция распределения случайной величины  $Z^* = \frac{Z - E(Z)}{\sqrt{Var(Z)}}$ , имеющей стандартизированное распределение Галланта и Нички  $GN^*$ , будет иметь вид:

$$\begin{aligned} F_{GN^*}(t; \theta) &= F_{Z^*}(t; \theta) = P(Z^* \leq t) = P\left(\frac{Z - E(Z)}{\sqrt{Var(Z)}} \leq t\right) = \\ &= P\left(Z < \sqrt{Var(Z)}t + E(Z)\right) = P\left(Z < \sqrt{M_{GN}(2; \theta) - M_{GN}(1; \theta)^2}t + M_{GN}(1; \theta)\right) = \end{aligned}$$

# Полупараметрические модели бинарного выбора

## Стандартизация распределения Галланта и Нички

- Распределение Галланта и Нички часто используют для того, что аппроксимировать неизвестное распределение случайной ошибки.
- При различных параметрах  $\theta$  данное распределение имеет различные математическое ожидание и дисперсию, что может вызвать проблемы с идентифицируемостью  $\beta$  в моделях бинарного выбора.
- Во избежание данных проблем распределение Галланта и Нички удобно стандартизировать к нулевому математическому ожиданию и единичной дисперсии.
- Обозначим через  $Z$  случайную величину, имеющую распределение Галланта и Нички с вектором параметров  $\theta$ . Тогда функция распределения случайной величины  $Z^* = \frac{Z - E(Z)}{\sqrt{Var(Z)}}$ , имеющей стандартизированное распределение Галланта и Нички  $GN^*$ , будет иметь вид:

$$\begin{aligned} F_{GN^*}(t; \theta) &= F_{Z^*}(t; \theta) = P(Z^* \leq t) = P\left(\frac{Z - E(Z)}{\sqrt{Var(Z)}} \leq t\right) = \\ &= P\left(Z < \sqrt{Var(Z)}t + E(Z)\right) = P\left(Z < \sqrt{M_{GN}(2; \theta) - M_{GN}(1; \theta)^2}t + M_{GN}(1; \theta)\right) = \\ &= F_Z\left(\sqrt{M_{GN}(2; \theta) - M_{GN}(1; \theta)^2}t + M_{GN}(1; \theta); \theta\right) = F_{GN}\left(\sqrt{M_{GN}(2; \theta) - M_{GN}(1; \theta)^2}t + M(1; \theta); \theta\right) \end{aligned}$$

# Полупараметрические модели бинарного выбора

## Метод Галланта и Нички

- Предположим, что  $\varepsilon_i$  имеет стандартизированное распределение Галланта и Нички  $GN^*$ , откуда:

$$P(y_i = 1|x_i) = 1 - F_{GN^*}(-x_i\beta; \theta)$$

# Полупараметрические модели бинарного выбора

## Метод Галланта и Нички

- Предположим, что  $\varepsilon_i$  имеет стандартизированное распределение Галланта и Нички  $GN^*$ , откуда:

$$P(y_i = 1|x_i) = 1 - F_{GN^*}(-x_i\beta; \theta)$$

- Предполагая, что распределение  $\varepsilon_i$  может быть достаточно точно приближено стандартизированным распределением Галланта и Нички можно оценить  $\beta$  и  $\theta$  за счет максимизации функции квази (псевдо) правдоподобия:

$$L(\beta, \theta; y|X) = \prod_{i:y_i=1} 1 - F_{GN^*}(-x_i\beta; \theta) \prod_{i:y_i=0} F_{GN^*}(-x_i\beta; \theta)$$

При этом степень полинома  $K$  может быть подобрана исходя из минимизации информационного критерия Акаике.



# Полупараметрические модели бинарного выбора

## Метод Галланта и Нички

- Предположим, что  $\varepsilon_i$  имеет стандартизированное распределение Галланта и Нички  $GN^*$ , откуда:

$$P(y_i = 1|x_i) = 1 - F_{GN^*}(-x_i\beta; \theta)$$

- Предполагая, что распределение  $\varepsilon_i$  может быть достаточно точно приближено стандартизированным распределением Галланта и Нички можно оценить  $\beta$  и  $\theta$  за счет максимизации функции квази (псевдо) правдоподобия:

$$L(\beta, \theta; y|X) = \prod_{i:y_i=1} 1 - F_{GN^*}(-x_i\beta; \theta) \prod_{i:y_i=0} F_{GN^*}(-x_i\beta; \theta)$$

При этом степень полинома  $K$  может быть подобрана исходя из минимизации информационного критерия Акаике.

- Приставка квази (псевдо) означает, что  $F_{GN^*}(-x_i\beta; \theta)$  отражает не истинное распределение случайной ошибки, а функцию, при помощи которой оно аппроксимируется. Поэтому для оценивания асимптотической ковариационной матрицы необходимо использовать сэндвич.

# Полупараметрические модели бинарного выбора

## Метод Галланта и Нички

- Предположим, что  $\varepsilon_i$  имеет стандартизированное распределение Галланта и Нички  $GN^*$ , откуда:

$$P(y_i = 1|x_i) = 1 - F_{GN^*}(-x_i\beta; \theta)$$

- Предполагая, что распределение  $\varepsilon_i$  может быть достаточно точно приближено стандартизированным распределением Галланта и Нички можно оценить  $\beta$  и  $\theta$  за счет максимизации функции квази (псевдо) правдоподобия:

$$L(\beta, \theta; y|X) = \prod_{i: y_i=1} 1 - F_{GN^*}(-x_i\beta; \theta) \prod_{i: y_i=0} F_{GN^*}(-x_i\beta; \theta)$$

При этом степень полинома  $K$  может быть подобрана исходя из минимизации информационного критерия Акаике.

- Приставка квази (псевдо) означает, что  $F_{GN^*}(-x_i\beta; \theta)$  отражает не истинное распределение случайной ошибки, а функцию, при помощи которой оно аппроксимируется. Поэтому для оценивания асимптотической ковариационной матрицы необходимо использовать сэндвич.
- Данный подход позволяет ослабить допущение о конкретной форме распределения случайной ошибки, однако требует существенных вычислительных мощностей для поиска глобального максимума функции квази правдоподобия.

# Модели бинарного выбора для панельных данных

## Модель бинарного выбора со случайными эффектами

- Через  $j$  обозначим индекс группы, к которой принадлежит наблюдение в панельной выборке, а через  $i \in \{1, \dots, T\}$  – индекс данного наблюдения в группе. Например, индекс  $j$  может отражать название фирмы, а индекс  $i$  – год наблюдения по этой фирме.

# Модели бинарного выбора для панельных данных

## Модель бинарного выбора со случайными эффектами

- Через  $j$  обозначим индекс группы, к которой принадлежит наблюдение в панельной выборке, а через  $i \in \{1, \dots, T\}$  – индекс данного наблюдения в группе. Например, индекс  $j$  может отражать название фирмы, а индекс  $i$  – год наблюдения по этой фирме.
- При наличии случайных эффектов случайная ошибка специфицируется как:

$$\varepsilon_{ij} = \varepsilon_{ij}^{(1)} + \varepsilon_j^{(2)}$$

Где  $\varepsilon_j^{(2)}$  именуется случайным эффектом. Предполагается, что  $\varepsilon_j^{(2)}$  и  $\varepsilon_{ij}^{(1)}$  независимы и не зависят от  $x_{ij}$ . Допущение о независимости  $\varepsilon_j^{(2)}$  и  $x_{ij}$  часто называется слабым местом модели.

# Модели бинарного выбора для панельных данных

## Модель бинарного выбора со случайными эффектами

- Через  $j$  обозначим индекс группы, к которой принадлежит наблюдение в панельной выборке, а через  $i \in \{1, \dots, T\}$  – индекс данного наблюдения в группе. Например, индекс  $j$  может отражать название фирмы, а индекс  $i$  – год наблюдения по этой фирме.
- При наличии случайных эффектов случайная ошибка специфицируется как:

$$\varepsilon_{ij} = \varepsilon_{ij}^{(1)} + \varepsilon_j^{(2)}$$

Где  $\varepsilon_j^{(2)}$  именуется случайным эффектом. Предполагается, что  $\varepsilon_j^{(2)}$  и  $\varepsilon_{ij}^{(1)}$  независимы и не зависят от  $x_{ij}$ . Допущение о независимости  $\varepsilon_j^{(2)}$  и  $x_{ij}$  часто называется слабым местом модели.

- Без потери общности предполагается, что  $E(\varepsilon_{ij}^{(1)}|x_{ij}) = E(\varepsilon_j^{(2)}|x_{ij}) = 0$ , а также  $Var(\varepsilon_{ij}^{(1)}|x_{ij}) = 1$  и  $Var(\varepsilon_j^{(2)}|x_{ij}) = \sigma^2$ .

# Модели бинарного выбора для панельных данных

## Модель бинарного выбора со случайными эффектами

- Через  $j$  обозначим индекс группы, к которой принадлежит наблюдение в панельной выборке, а через  $i \in \{1, \dots, T\}$  – индекс данного наблюдения в группе. Например, индекс  $j$  может отражать название фирмы, а индекс  $i$  – год наблюдения по этой фирме.
- При наличии случайных эффектов случайная ошибка специфицируется как:

$$\varepsilon_{ij} = \varepsilon_{ij}^{(1)} + \varepsilon_j^{(2)}$$

Где  $\varepsilon_j^{(2)}$  именуется случайным эффектом. Предполагается, что  $\varepsilon_j^{(2)}$  и  $\varepsilon_{ij}^{(1)}$  независимы и не зависят от  $x_{ij}$ . Допущение о независимости  $\varepsilon_j^{(2)}$  и  $x_{ij}$  часто называется слабым местом модели.

- Без потери общности предполагается, что  $E(\varepsilon_{ij}^{(1)}|x_{ij}) = E(\varepsilon_j^{(2)}|x_{ij}) = 0$ , а также  $Var(\varepsilon_{ij}^{(1)}|x_{ij}) = 1$  и  $Var(\varepsilon_j^{(2)}|x_{ij}) = \sigma^2$ .
- Наличие случайных эффектов в модели можно протестировать как  $H_0 : \sigma^2 = 0$ .

- Обратим внимание, что (используя law of total expectation):

$$P(y_{ij} = 1|x_{ij}) = P(\varepsilon_{ij}^{(1)} + \varepsilon_j^{(2)} > -x_{ij}\beta|x_{ij}) = P(\varepsilon_{ij}^{(1)} > -\varepsilon_j^{(2)} - x_{ij}\beta|x_{ij}) =$$

# Модели бинарного выбора для панельных данных

## Расчет вероятностей

- Обратим внимание, что (используя law of total expectation):

$$\begin{aligned} P(y_{ij} = 1|x_{ij}) &= P(\varepsilon_{ij}^{(1)} + \varepsilon_j^{(2)} > -x_{ij}\beta|x_{ij}) = P(\varepsilon_{ij}^{(1)} > -\varepsilon_j^{(2)} - x_{ij}\beta|x_{ij}) = \\ &= E \left( P(\varepsilon_{ij}^{(1)} > -\varepsilon_j^{(2)} - x_{ij}\beta|x_{ij}) \right) = E_{\varepsilon_j^{(2)}} \left( E \left[ P \left( \varepsilon_{ij}^{(1)} > -\varepsilon_j^{(2)} - x_{ij}\beta|x_{ij}, \varepsilon_j^{(2)} \right) \right] \right) = \end{aligned}$$



- Обратим внимание, что (используя law of total expectation):

$$\begin{aligned} P(y_{ij} = 1|x_{ij}) &= P(\varepsilon_{ij}^{(1)} + \varepsilon_j^{(2)} > -x_{ij}\beta|x_{ij}) = P(\varepsilon_{ij}^{(1)} > -\varepsilon_j^{(2)} - x_{ij}\beta|x_{ij}) = \\ &= E \left( P(\varepsilon_{ij}^{(1)} > -\varepsilon_j^{(2)} - x_{ij}\beta|x_{ij}) \right) = E_{\varepsilon_j^{(2)}} \left( E \left[ P \left( \varepsilon_{ij}^{(1)} > -\varepsilon_j^{(2)} - x_{ij}\beta|x_{ij}, \varepsilon_j^{(2)} \right) \right] \right) = \\ &= E_{\varepsilon_j^{(2)}} \left( P \left( \varepsilon_{ij}^{(1)} > -\varepsilon_j^{(2)} - x_{ij}\beta|x_{ij} \right) \right) = E_{\varepsilon_j^{(2)}} \left( 1 - F_{\varepsilon_{ij}^{(1)}} \left( -x_{ij}\beta - \varepsilon_j^{(2)} \right) \right) \end{aligned}$$

# Модели бинарного выбора для панельных данных

## Расчет вероятностей

- Обратим внимание, что (используя law of total expectation):

$$\begin{aligned} P(y_{ij} = 1|x_{ij}) &= P(\varepsilon_{ij}^{(1)} + \varepsilon_j^{(2)} > -x_{ij}\beta|x_{ij}) = P(\varepsilon_{ij}^{(1)} > -\varepsilon_j^{(2)} - x_{ij}\beta|x_{ij}) = \\ &= E \left( P(\varepsilon_{ij}^{(1)} > -\varepsilon_j^{(2)} - x_{ij}\beta|x_{ij}) \right) = E_{\varepsilon_j^{(2)}} \left( E \left[ P \left( \varepsilon_{ij}^{(1)} > -\varepsilon_j^{(2)} - x_{ij}\beta|x_{ij}, \varepsilon_j^{(2)} \right) \right] \right) = \\ &= E_{\varepsilon_j^{(2)}} \left( P \left( \varepsilon_{ij}^{(1)} > -\varepsilon_j^{(2)} - x_{ij}\beta|x_{ij} \right) \right) = E_{\varepsilon_j^{(2)}} \left( 1 - F_{\varepsilon_{ij}^{(1)}} \left( -x_{ij}\beta - \varepsilon_j^{(2)} \right) \right) \end{aligned}$$

- Применяя закон больших чисел (ЗБЧ), соответствующее математическое ожидание можно приблизительно вычислить, насимулировав большое количество  $q$  независимых случайных величин  $Z_1, \dots, Z_q$  из распределения такого же, как у  $\varepsilon_j^{(2)}$ :

# Модели бинарного выбора для панельных данных

## Расчет вероятностей

- Обратим внимание, что (используя law of total expectation):

$$\begin{aligned} P(y_{ij} = 1|x_{ij}) &= P(\varepsilon_{ij}^{(1)} + \varepsilon_j^{(2)} > -x_{ij}\beta|x_{ij}) = P(\varepsilon_{ij}^{(1)} > -\varepsilon_j^{(2)} - x_{ij}\beta|x_{ij}) = \\ &= E \left( P(\varepsilon_{ij}^{(1)} > -\varepsilon_j^{(2)} - x_{ij}\beta|x_{ij}) \right) = E_{\varepsilon_j^{(2)}} \left( E \left[ P \left( \varepsilon_{ij}^{(1)} > -\varepsilon_j^{(2)} - x_{ij}\beta|x_{ij}, \varepsilon_j^{(2)} \right) \right] \right) = \\ &= E_{\varepsilon_j^{(2)}} \left( P \left( \varepsilon_{ij}^{(1)} > -\varepsilon_j^{(2)} - x_{ij}\beta|x_{ij} \right) \right) = E_{\varepsilon_j^{(2)}} \left( 1 - F_{\varepsilon_{ij}^{(1)}} \left( -x_{ij}\beta - \varepsilon_j^{(2)} \right) \right) \end{aligned}$$

- Применяя закон больших чисел (ЗБЧ), соответствующее математическое ожидание можно приблизительно вычислить, насимулировав большое количество  $q$  независимых случайных величин  $Z_1, \dots, Z_q$  из распределения такого же, как у  $\varepsilon_j^{(2)}$ :

$$P(y_{ij} = 1|x_i) \approx \frac{1}{q} \sum_{i=1}^q 1 - F_{\varepsilon_{ij}^{(1)}}(-x_{ij}\beta - Z_q)$$

# Модели бинарного выбора для панельных данных

Оценивание с помощью симуляционного метода максимального правдоподобия

- По аналогии можно рассчитывать и совместные вероятности, например, обозначая через  $Z_1^{(1)}, \dots, Z_q^{(1)}$  и  $Z_1^{(2)}, \dots, Z_q^{(2)}$  две независимые выборки из того же распределения, что и  $\varepsilon_j^{(2)}$ , получаем:

$$P(y_{1j} = 1, y_{2j} = 1 | x_{1j}, x_{2j}) = E_{\varepsilon_j^{(2)}} \left( E \left[ P \left( \varepsilon_{1j}^{(1)} > -\varepsilon_j^{(2)} - x_{1j}\beta, \varepsilon_{2j}^{(1)} > -\varepsilon_j^{(2)} - x_{2j}\beta | x_{1j}, x_{2j}, \varepsilon_j^{(2)} \right) \right] \right) =$$

# Модели бинарного выбора для панельных данных

Оценивание с помощью симуляционного метода максимального правдоподобия

- По аналогии можно рассчитывать и совместные вероятности, например, обозначая через  $Z_1^{(1)}, \dots, Z_q^{(1)}$  и  $Z_1^{(2)}, \dots, Z_q^{(2)}$  две независимые выборки из того же распределения, что и  $\varepsilon_j^{(2)}$ , получаем:

$$\begin{aligned} P(y_{1j} = 1, y_{2j} = 1 | x_{1j}, x_{2j}) &= E_{\varepsilon_j^{(2)}} \left( E \left[ P \left( \varepsilon_{1j}^{(1)} > -\varepsilon_j^{(2)} - x_{1j}\beta, \varepsilon_{2j}^{(1)} > -\varepsilon_j^{(2)} - x_{2j}\beta | x_{1j}, x_{2j}, \varepsilon_j^{(2)} \right) \right] \right) = \\ &= E_{\varepsilon_j^{(2)}} \left( E \left[ P \left( \varepsilon_{1j}^{(1)} > -\varepsilon_j^{(2)} - x_{1j}\beta | x_{1j}, \varepsilon_j^{(2)} \right) P \left( \varepsilon_{2j}^{(1)} > -\varepsilon_j^{(2)} - x_{2j}\beta | x_{2j}, \varepsilon_j^{(2)} \right) \right] \right) \approx \end{aligned}$$

# Модели бинарного выбора для панельных данных

Оценивание с помощью симуляционного метода максимального правдоподобия

- По аналогии можно рассчитывать и совместные вероятности, например, обозначая через  $Z_1^{(1)}, \dots, Z_q^{(1)}$  и  $Z_1^{(2)}, \dots, Z_q^{(2)}$  две независимые выборки из того же распределения, что и  $\varepsilon_j^{(2)}$ , получаем:

$$\begin{aligned} P(y_{1j} = 1, y_{2j} = 1 | x_{1j}, x_{2j}) &= E_{\varepsilon_j^{(2)}} \left( E \left[ P \left( \varepsilon_{1j}^{(1)} > -\varepsilon_j^{(2)} - x_{1j}\beta, \varepsilon_{2j}^{(1)} > -\varepsilon_j^{(2)} - x_{2j}\beta | x_{1j}, x_{2j}, \varepsilon_j^{(2)} \right) \right] \right) = \\ &= E_{\varepsilon_j^{(2)}} \left( E \left[ P \left( \varepsilon_{1j}^{(1)} > -\varepsilon_j^{(2)} - x_{1j}\beta | x_{1j}, \varepsilon_j^{(2)} \right) P \left( \varepsilon_{2j}^{(1)} > -\varepsilon_j^{(2)} - x_{2j}\beta | x_{2j}, \varepsilon_j^{(2)} \right) \right] \right) \approx \\ &\approx \frac{1}{q} \sum_{i=1}^q \left( 1 - F_{\varepsilon_{ij}^{(1)}} \left( -Z_q^{(1)} - x_{1j}\beta \right) \right) \left( 1 - F_{\varepsilon_{ij}^{(1)}} \left( -Z_q^{(2)} - x_{2j}\beta \right) \right) \end{aligned}$$

# Модели бинарного выбора для панельных данных

Оценивание с помощью симуляционного метода максимального правдоподобия

- По аналогии можно рассчитывать и совместные вероятности, например, обозначая через  $Z_1^{(1)}, \dots, Z_q^{(1)}$  и  $Z_1^{(2)}, \dots, Z_q^{(2)}$  две независимые выборки из того же распределения, что и  $\varepsilon_j^{(2)}$ , получаем:

$$\begin{aligned} P(y_{1j} = 1, y_{2j} = 1 | x_{1j}, x_{2j}) &= E_{\varepsilon_j^{(2)}} \left( E \left[ P \left( \varepsilon_{1j}^{(1)} > -\varepsilon_j^{(2)} - x_{1j}\beta, \varepsilon_{2j}^{(1)} > -\varepsilon_j^{(2)} - x_{2j}\beta | x_{1j}, x_{2j}, \varepsilon_j^{(2)} \right) \right] \right) = \\ &= E_{\varepsilon_j^{(2)}} \left( E \left[ P \left( \varepsilon_{1j}^{(1)} > -\varepsilon_j^{(2)} - x_{1j}\beta | x_{1j}, \varepsilon_j^{(2)} \right) P \left( \varepsilon_{2j}^{(1)} > -\varepsilon_j^{(2)} - x_{2j}\beta | x_{2j}, \varepsilon_j^{(2)} \right) \right] \right) \approx \\ &\approx \frac{1}{q} \sum_{i=1}^q \left( 1 - F_{\varepsilon_{ij}^{(1)}} \left( -Z_q^{(1)} - x_{1j}\beta \right) \right) \left( 1 - F_{\varepsilon_{ij}^{(1)}} \left( -Z_q^{(2)} - x_{2j}\beta \right) \right) \end{aligned}$$

- Функция правдоподобия модели бинарного выбора со случайными эффектами будет иметь вид:

$$L(\beta, \sigma^2; y|X) = \prod_{j: y_{1j}=0, \dots, y_{Tj}=0} P(y_{1j} = 0, \dots, y_{Tj} = 0) \times \dots \times \prod_{j: y_{1j}=1, \dots, y_{Tj}=1} P(y_{1j} = 1, \dots, y_{Tj} = 1)$$

# Модели бинарного выбора для панельных данных

Оценивание с помощью симуляционного метода максимального правдоподобия

- По аналогии можно рассчитывать и совместные вероятности, например, обозначая через  $Z_1^{(1)}, \dots, Z_q^{(1)}$  и  $Z_1^{(2)}, \dots, Z_q^{(2)}$  две независимые выборки из того же распределения, что и  $\varepsilon_j^{(2)}$ , получаем:

$$\begin{aligned} P(y_{1j} = 1, y_{2j} = 1 | x_{1j}, x_{2j}) &= E_{\varepsilon_j^{(2)}} \left( E \left[ P \left( \varepsilon_{1j}^{(1)} > -\varepsilon_j^{(2)} - x_{1j}\beta, \varepsilon_{2j}^{(1)} > -\varepsilon_j^{(2)} - x_{2j}\beta | x_{1j}, x_{2j}, \varepsilon_j^{(2)} \right) \right] \right) = \\ &= E_{\varepsilon_j^{(2)}} \left( E \left[ P \left( \varepsilon_{1j}^{(1)} > -\varepsilon_j^{(2)} - x_{1j}\beta | x_{1j}, \varepsilon_j^{(2)} \right) P \left( \varepsilon_{2j}^{(1)} > -\varepsilon_j^{(2)} - x_{2j}\beta | x_{2j}, \varepsilon_j^{(2)} \right) \right] \right) \approx \\ &\approx \frac{1}{q} \sum_{i=1}^q \left( 1 - F_{\varepsilon_{ij}^{(1)}} \left( -Z_q^{(1)} - x_{1j}\beta \right) \right) \left( 1 - F_{\varepsilon_{ij}^{(1)}} \left( -Z_q^{(2)} - x_{2j}\beta \right) \right) \end{aligned}$$

- Функция правдоподобия модели бинарного выбора со случайными эффектами будет иметь вид:

$$L(\beta, \sigma^2; y|X) = \prod_{j: y_{1j}=0, \dots, y_{Tj}=0} P(y_{1j} = 0, \dots, y_{Tj} = 0) \times \dots \times \prod_{j: y_{1j}=1, \dots, y_{Tj}=1} P(y_{1j} = 1, \dots, y_{Tj} = 1)$$

Максимизация соответствующей функции с использованием аппроксимаций вероятностей, указанных выше, именуется симуляционным методом максимального правдоподобия.



# Модели бинарного выбора со случайными коэффициентами

## Формулировка и оценивание

- Рассмотрим модель, в которой у каждого индивида различаются коэффициенты, отражающие влияние регрессоров на латентную переменную:

$$y_i^* = x_i \beta_i + \varepsilon_i$$

# Модели бинарного выбора со случайными коэффициентами

## Формулировка и оценивание

- Рассмотрим модель, в которой у каждого индивида различаются коэффициенты, отражающие влияние регрессоров на латентную переменную:

$$y_i^* = x_i \beta_i + \varepsilon_i$$

- Для того, чтобы учесть возможность различия эффектов различных переменных на зависимую бинарную переменную можно предположить, что все регрессионные коэффициенты являются случайными величинами. Для простоты предположим, что они имеют нормальное распределение  $\beta_{ik} \sim \mathcal{N}(\beta_k, \sigma_k^2)$ .

# Модели бинарного выбора со случайными коэффициентами

## Формулировка и оценивание

- Рассмотрим модель, в которой у каждого индивида различаются коэффициенты, отражающие влияние регрессоров на латентную переменную:

$$y_i^* = x_i \beta_i + \varepsilon_i$$

- Для того, чтобы учесть возможность различия эффектов различных переменных на зависимую бинарную переменную можно предположить, что все регрессионные коэффициенты являются случайными величинами. Для простоты предположим, что они имеют нормальное распределение  $\beta_{ik} \sim \mathcal{N}(\beta_k, \sigma_k^2)$ .
- По аналогии с моделями со случайными эффектами для оценивания параметров распределения случайных коэффициентов, то есть  $\beta_k$  и  $\sigma_k^2$ , можно воспользоваться методом симуляционного правдоподобия.

# Модели бинарного выбора со случайными коэффициентами

## Формулировка и оценивание

- Рассмотрим модель, в которой у каждого индивида различаются коэффициенты, отражающие влияние регрессоров на латентную переменную:

$$y_i^* = x_i \beta_i + \varepsilon_i$$

- Для того, чтобы учесть возможность различия эффектов различных переменных на зависимую бинарную переменную можно предположить, что все регрессионные коэффициенты являются случайными величинами. Для простоты предположим, что они имеют нормальное распределение  $\beta_{ik} \sim \mathcal{N}(\beta_k, \sigma_k^2)$ .
- По аналогии с моделями со случайными эффектами для оценивания параметров распределения случайных коэффициентов, то есть  $\beta_k$  и  $\sigma_k^2$ , можно воспользоваться методом симуляционного правдоподобия.
- При  $\sigma_k^2 = 0$  коэффициент является не случайным, а детерминированным, что можно использовать для тестирования соответствующей гипотезы.

# Модели бинарного выбора со случайными коэффициентами

## Формулировка и оценивание

- Рассмотрим модель, в которой у каждого индивида различаются коэффициенты, отражающие влияние регрессоров на латентную переменную:

$$y_i^* = x_i \beta_i + \varepsilon_i$$

- Для того, чтобы учесть возможность различия эффектов различных переменных на зависимую бинарную переменную можно предположить, что все регрессионные коэффициенты являются случайными величинами. Для простоты предположим, что они имеют нормальное распределение  $\beta_{ik} \sim \mathcal{N}(\beta_k, \sigma_k^2)$ .
- По аналогии с моделями со случайными эффектами для оценивания параметров распределения случайных коэффициентов, то есть  $\beta_k$  и  $\sigma_k^2$ , можно воспользоваться методом симуляционного правдоподобия.
- При  $\sigma_k^2 = 0$  коэффициент является не случайным, а детерминированным, что можно использовать для тестирования соответствующей гипотезы.
- Существенный недостаток данной модели заключается в нереалистичном допущении о независимости  $\beta_{ik}$  и  $x_i$ . В таком случае предположение о гетерогенности эффекта регрессоров в популяции вступает, в содержательном смысле, в противоречие с допущением о том, что эта гетерогенность не связана с наблюдаемыми характеристиками исследуемых объектов  $x_i$ .